

Edge-Boosted U-Net for 2D Medical Image Segmentation

≡ 분류	모델 바운더리연구 엣지
≡ 링크	https://ieeexplore.ieee.org/abstract/document/8906008

논문 "Edge-Boosted U-Net for 2D Medical Image Segmentation"의 요약:

애플스트렉트

의료 이미지 분할을 위한 새로운 네트워크인 Edge-Boosted U-Net(EU-Net) 제안. 이 네트워크는 U-Net 구조를 기반으로 하며, 엣지 정보와 다중 레벨 특징을 효과적으로 결합하여 분할 성능을 향상시킴. 다양한 공개 데이터셋에서 실험을 통해 성능 우수성을 입증.

1. 서론:

의료 이미지 분할의 중요성과 기존 방법의 한계 설명. U-Net의 구조와 그 개선 필요성 강조.

2. 제안된 방법:

EU-Net은 세 가지 주요 구성 요소로 이루어짐:

- **Edge Aggregation Path (EAP):** 엣지 정보를 보존하고 다중 레벨 특징을 결합.
- **Feature Attention Block (FAB):** 채널 간 상관관계를 캡처하여 정보 전달.
- **Feature Fusion Block (FFB):** 디코더와 EAP의 특징을 융합하여 더 정교한 분할 생성.

3. 실험 및 결과:

세 가지 공개 의료 이미지 데이터셋에서 EU-Net의 성능을 평가. EAP와 FFB의 효과를 분석하고, 기존 방법들과 비교하여 성능 우수성을 입증.

4. 결론:

EU-Net이 의료 이미지 분할에서 효과적임을 강조하며, 향후 연구 방향 제시.

I. 서론:

의료 이미지 분할은 컴퓨터 보조 진단에서 중요한 작업으로, 높은 정확도가 요구됨. 이는 의료 이미지의 세부 정보가 진단에 중요한 역할을 하기 때문. 기존의 방법들은 다양성과 복잡성으로 인해 어려움을 겪고 있으며, 특히 작은 병변이나 이상 징후의 경계 정보를 정확히 분할하는 것이 중요함. 본 논문에서는 이러한 문제를 해결하기 위해 Edge-Boosted U-Net(EU-Net)을 제안하며, 이 네트워크는 U-Net 구조를 기반으로 하여 엣지 정보와 다중 레벨 특징을 효과적으로 활용하여 성능을 향상시킴.

II. 관련 연구:

의료 이미지 분할에 대한 다양한 접근 방식이 존재함. U-Net과 그 변형들은 뛰어난 성능을 보이며, 특히 U-Net++는 디코더에서 고해상도 특징 맵을 융합하지만 계산 비용이 많이 듦. DenseUNet은 밀접하게 연결된 경로와 스킵 연결을 통해 성능을 개선하고, ∇ N-Net은 반복 잔차 합성곱 유닛을 사용하여 피부암 분할에서 우수한 성능을 달성함. 그러나 대부분의 U-Net 계열 네트워크는 다중 스케일 특징 맵의 추상적인 정보만 활용하고, 세부적인 엣지 정보를 보존하지 못함. 이를 해결하기 위해, 본 연구에서는 엣지 정보를 효과적으로 활용할 수 있는 새로운 방법을 제안함.

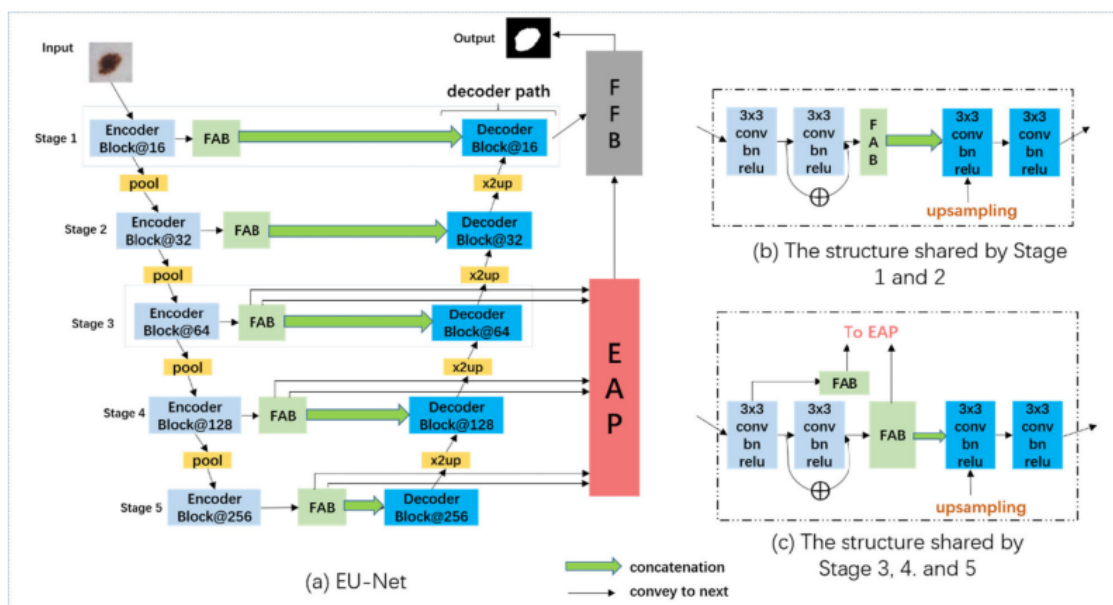


FIGURE 1. An overview of the proposed Edge-boosted U-Net. (a) shows the whole architecture of our proposed network. @X indicates that the number of feature maps is X. In (a), the parts of stage 1 and 2 share the structure in (b) while the parts of stage 3, 4, and 5 share the structure in (c).

FIGURE 1. 제안된 Edge-Boosted U-Net의 개요:

(a)에서는 제안된 네트워크의 전체 구조를 보여줌. @X는 특징 맵의 수가 X임을 나타냄. (a)에서 1단계와 2단계의 부분은 (b)에서 공유되는 구조를 가지며, 3단계, 4단계, 5단계의 부분은 (c)에서 공유되는 구조를 가짐.

III. 제안된 방법

제안된 Edge-Boosted U-Net (EU-Net)은 기본 U-Net 구조에 세 가지 추가 구성 요소를 통합하여 의료 이미지 분할 성능을 향상시키고자 함. 이 네트워크는 다음과 같은 주요 구성 요소로 이루어져 있음:

1. Feature Attention Block (FAB):

- 인코더 부분에 채널 간 정보를 강화하기 위해 설계됨. FAB는 인코더에서 생성된 다중 레벨 특징 맵에 채널 가중치를 적용하여 더 정보가 풍부한 특징을 생성함.

2. Edge Aggregation Path (EAP):

- 엣지 관련 특징을 캡처하기 위해 설계됨. EAP는 인코더의 마지막 세 단계에서 추출된 특징 맵 쌍을 입력으로 받아, 각 단계의 세부적이고 추상적인 특징을 결합하여 엣지 정보를 강화함.

3. Feature Fusion Block (FFB):

- 디코더 경로의 특징과 EAP에서 추출된 특징을 융합하여 더 정교한 분할 결과를 생성함. FFB는 다양한 수준의 특징을 통합하여 최종 출력의 품질을 향상시킴.

EU-Net은 다섯 개의 단계로 나뉘며, 각 단계에서 인코더의 특징 맵을 활용하여 디코더 경로에서 해상도를 복원함. 이러한 구조는 의료 이미지의 전반적인 구조를 잘 반영하며, 엣지 정보와 다중 레벨 특징을 효과적으로 활용하여 분할 성능을 개선함.

Feature Attention Block (FAB):




FIGURE 2. Details of Feature Attention Block (FAB).

Feature Attention Block (FAB)은 Edge-Boosted U-Net (EU-Net)에서 인코더 부분에 통합된 경량화된 모듈로, 채널 간의 정보를 강화하여 특징 맵의 표현력을 높이는 역할을 함. FAB의 주요 기능과 구조는 다음과 같음:

1. 채널 간 정보 강화:

- FAB는 인코더에서 생성된 특징 맵에 대해 채널 간의 중요도를 평가하여, 각 채널의 가중치를 조정함. 이를 통해 중요한 특징이 강조되고 덜 중요한 특징은 억제됨.

2. 가중치 계산:

- FAB은 입력 특징 맵을 두 개의 경로로 나누어, 하나는 평균 풀링을 통해 전역적인 정보를 캡처하고, 다른 하나는 최대 풀링을 통해 지역적인 정보를 캡처함. 이 두 경로에서 얻은 정보를 결합하여 각 채널의 가중치를 계산함.

3. 특징 맵 재구성:

- 계산된 가중치는 원래의 특징 맵에 곱해져, 각 채널의 중요도에 따라 조정된 새로운 특징 맵을 생성함. 이 과정은 네트워크가 더 유용한 정보를 학습하도록 돕고, 최종적으로 더 정교한 분할 결과를 도출하게 함.

4. 효율성:

- FAB은 경량화된 구조로 설계되어, 계산 비용을 최소화하면서도 성능을 향상시킬 수 있도록 함. 이는 의료 이미지 분할과 같은 복잡한 작업에서 특히 유용함.

FAB의 도입으로 인해 EU-Net은 인코더에서 생성된 특징 맵의 정보가 더욱 풍부해지고, 디코더에서의 결합 과정에서 더 나은 성능을 발휘하게 됨. 이러한 방식은 네트워크가 더 정확한 분할을 수행할 수 있도록 지원함.

Edge Aggregation Path (EAP):




FIGURE 3. Details of Edge Aggregation Path (EAP).

Edge Aggregation Path (EAP)는 Edge-Boosted U-Net (EU-Net)에서 엣지 관련 특징을 강화하고, 의료 이미지 분할 성능을 향상시키기 위해 설계된 구성 요소임. EAP의 주요 기능과 구조는 다음과 같음:

1. 엣지 정보 강화:

- EAP는 의료 이미지에서 분할 오류가 주로 엣지 주변에 집중되는 경향이 있다는 점을 고려하여, 엣지 정보를 강조하는 데 중점을 둠. 이는 분할 객체의 형태를 정확하게 반영하고, 의료 진단의 정확성을 높이는 데 기여함.

2. 다단계 특징 결합:

- EAP는 인코더의 마지막 세 단계에서 추출된 특징 맵 쌍을 입력으로 받아, 각 단계에서의 세부적이고 추상적인 특징을 결합함. 이를 통해 다양한 수준의 정보를 통합하여 더 풍부한 특징 표현을 생성함.

3. 특징 맵 쌍의 입력:

- EAP는 각 단계에서 세부적인 특징 맵과 추상적인 특징 맵을 쌍으로 입력받아, 이들 간의 상호작용을 통해 더 나은 특징 표현을 도출함. 이러한 방식은 네트워크가 엣지와 관련된 정보를 효과적으로 학습하도록 돕고, 최종 분할 성능을 향상시킴.

4. 효율적인 계산:

- EAP는 특징 맵의 결합을 통해 정보의 손실을 최소화하고, 계산 비용을 줄이면서도 성능을 극대화할 수 있도록 설계됨. 이는 특히 의료 이미지와 같은 복잡한 데이터에서 유용함.

Feature Fusion Block (FFB):




FIGURE 4. Details of Feature Fusion Block (FFB).

Feature Fusion Block (FFB)는 Edge-Boosted U-Net (EU-Net)에서 디코더 경로와 Edge Aggregation Path (EAP)에서 추출된 특징을 결합하여 최종 분할 결과를 생성하는 중요한 구성 요소임. FFB의 주요 기능과 구조는 다음과 같음:

1. 특징 결합:

- FFB는 디코더 경로에서 얻은 특징 맵과 EAP에서 얻은 특징 맵을 결합하여, 두 경로의 정보를 통합함. 이를 통해 서로 다른 정보가 결합되어 더 풍부하고 정교한 특징 표현을 생성함.

2. 픽셀 단위의 합산:

- FFB는 디코더 경로와 EAP에서의 특징 맵에 각각 1×1 컨볼루션을 적용한 후, 이들 특징 맵을 픽셀 단위로 합산함. 이 과정은 두 경로에서의 정보를 효과적으로 통합하여 최종 출력의 품질을 향상시킴.

3. 소프트맥스 함수 적용:

- 디코더 경로의 특징 맵에 소프트맥스 함수를 적용하여, 각 픽셀에 대한 가중치를 계산함. 이 가중치는 최종 결합된 특징 맵에 반영되어, 더 중요한 정보가 강조되도록 함.

4. 최종 출력 생성:

- FFB의 출력은 최종 분할 결과로, 이 결과는 의료 이미지의 세밀한 분할을 가능하게 함. FFB는 네트워크가 다양한 정보 소스를 효과적으로 활용하여, 더 정확한 분할을 수행할 수 있도록 지원함.

5. 효율성 및 성능 향상:

- FFB는 간단하면서도 효과적인 구조로 설계되어, 계산 비용을 최소화하면서도 성능을 극대화할 수 있도록 함. 이는 특히 복잡한 의료 이미지 분할 작업에서 유용함.

IV. EXPERIMENTS:

이 섹션에서는 Edge-Boosted U-Net (EU-Net)의 성능을 평가하기 위해 수행된 실험에 대해 설명함. 실험은 다양한 의료 이미지 데이터셋을 사용하여 EU-Net의 효과성과 강건성을 검증하는 데 중점을 둠.

1. 데이터셋:

- 실험에서는 세 가지 다양한 의료 이미지 모달리티를 사용함. 각 데이터셋은 EU-Net의 성능을 평가하기 위해 선택되었으며, 각 데이터셋의 특성과 난이도는 서로 다름.

2. 비교 네트워크:

- EU-Net의 성능을 평가하기 위해 여러 다른 네트워크 구조와 비교함. 여기에는 다음과 같은 네트워크가 포함됨:
 - **Single:** EAP가 없는 기본 U-Net 구조.
 - **Sum-Fusion:** 디코더 경로와 EAP의 특징을 단순 합산하여 결합한 네트워크.
 - **Cat-Fusion:** 디코더 경로와 EAP의 특징을 단순 연결하여 결합한 네트워크.
 - **FFB:** EU-Net의 전체 구조로, EAP와 디코더 경로의 특징을 FFB를 통해 결합함.

3. 성능 평가 지표:

- 실험 결과는 Intersection over Union (IoU)와 Dice 계수를 사용하여 평가됨. 이 두 지표는 분할 성능을 정량적으로 측정하는 데 널리 사용됨.

4. 실험 결과:

- 실험 결과는 EU-Net이 다른 네트워크 구조에 비해 IoU와 Dice 점수에서 우수한 성능을 보였음을 나타냄. 특히, EAP와 FFB를 포함한 EU-Net은 각 데이터셋에서 가장 높은 정확도를 기록함.
- 예를 들어, Montgomery CXR 데이터셋에서 EU-Net은 IoU 95.80%와 Dice 97.38%를 달성하였으며, 이는 다른 네트워크보다 높은 수치임.

5. 시각화 결과:

- 실험에서는 DSB2018, ISIC2018, Montgomery CXR 데이터셋에 대한 시각화 결과도 제공됨. 이 결과들은 EU-Net이 생성한 마스크가 실제 정답에 가장 근접함을

보여줌. 이는 EAP와 디코더 경로의 효과적인 정보 통합 덕분임.

6. 결론:

- 실험 결과는 EU-Net이 의료 이미지 분할 작업에서 효과적이며, EAP와 FFB의 도입이 성능 향상에 기여함을 입증함. 이러한 결과는 EU-Net이 다양한 의료 이미지 데이터셋에서 강력한 성능을 발휘할 수 있음을 시사함.

이러한 실험을 통해 EU-Net의 구조적 장점과 성능을 명확히 보여주며, 의료 이미지 분할 분야에서의 활용 가능성을 제시함.

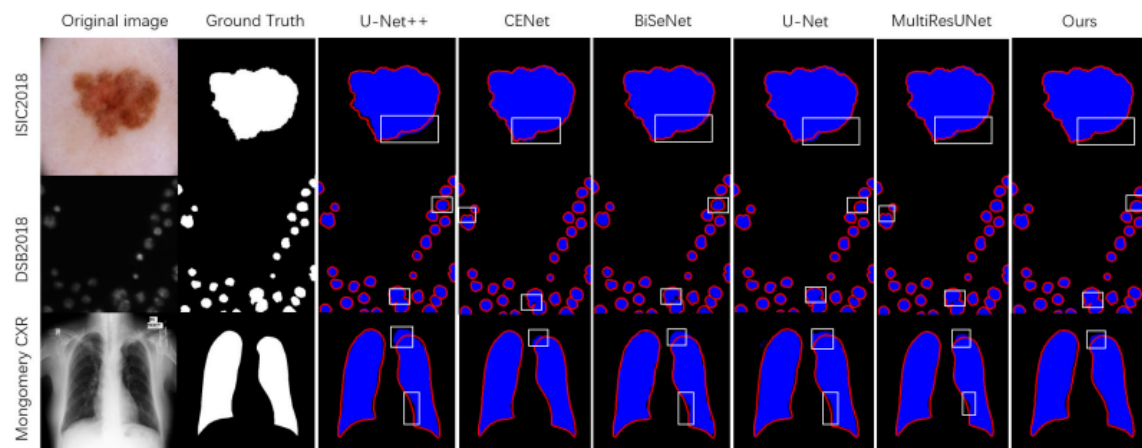


FIGURE 11. Visualized results on different datasets. (The ground truth field is outlined with red, while the predicted field is filled with blue. The differences in results are marked with white blanks but are not limited to these white blanks).

TABLE 3. Comparison results compared with other methods.

Dataset(modality)	Method	IoU(%)(\pm std)	Dice(%)(\pm std)
ISIC2018 (dermoscopy)	BiSeNet [22]	79.32 \pm 0.008	86.95 \pm 0.009
	U-Net [13]	78.22 \pm 0.009	86.25 \pm 0.009
	MultiResUNet [33]	80.29 \pm 0.007	87.96 \pm 0.008
	CE-Net [34]	81.12 \pm 0.007	87.91 \pm 0.009
	U-Net++ [14]	79.98 \pm 0.009	87.76 \pm 0.009
	EU-Net	82.43\pm0.009	89.28\pm0.009
DSB2018 (fluorescence microscopy)	BiSeNet	76.64 \pm 0.008	86.14 \pm 0.008
	U-Net	84.10 \pm 0.009	90.95 \pm 0.009
	MultiResUNet	86.78 \pm 0.012	92.11 \pm 0.011
	CE-Net	87.61 \pm 0.010	92.93 \pm 0.009
	U-Net++	87.23 \pm 0.009	92.38 \pm 0.008
	EU-Net	88.14\pm0.008	94.24\pm0.009
Montgomery CXR (X-ray)	BiSeNet	94.32 \pm 0.010	97.05 \pm 0.010
	U-Net	95.39 \pm 0.009	97.61 \pm 0.011
	MultiResUNet	95.46 \pm 0.012	97.67 \pm 0.011
	CE-Net	95.53 \pm 0.008	97.70 \pm 0.009
	U-Net++	95.53 \pm 0.011	97.68 \pm 0.010
	EU-Net	95.80\pm0.009	97.83\pm0.010