



# 서베이 논문

소유자	유림 오
태그	

[qwac141.pdf](#)

## 큰 카테고리

위 논문에서는

세그멘테이션을 위한 방법들로

딥러닝 기법: 설문지는 딥러닝을 활용하여 MRI 이미지에서 복잡한 특징을 자동으로 학습하는 뇌종양 분할을 위한 새로운 CNN 기반 접근 방식을 제시할 가능성이 높습니다. 이러한 접근 방식에는 종양 분할의 정확성과 효율성을 향상시키는 혁신적인 아키텍처, 훈련 전략 또는 최적화 기술이 포함될 수 있습니다.

하이브리드 기술: 설문지는 딥 러닝을 기존 이미지 처리 기술과 통합하거나 분할 정확도를 향상시키기 위해 MRI 데이터의 여러 양식을 통합하는 등 다양한 접근 방식을 결합하는 새로운 하이브리드 분할 방법을 소개할 수 있습니다.

최첨단 접근 방식: 이 조사 논문은 MRI 영상에서 뇌종양을 정확하게 식별하고 묘사하는 데 상당한 발전을 보여준 최첨단 분할 방법을 소개할 것으로 보입니다. 이러한 접근 방식에는 최첨단 딥 러닝 아키텍처, 새로운 특징 추출 방법 또는 분할 결과를 향상시키기 위한 혁신적인 후처리 기술이 포함될 수 있습니다.

지도 분할: 설문지는 정확한 분할을 위해 뇌종양과 건강한 조직의 특성을 학습하기 위해 레이블이 지정된 훈련 데이터를 활용하는 새로운 지도 분할 방법을 소개할 수 있습니다. 이러한 방법에는 분할 정확도를 향상시키기 위해 전문가 주석이나 실측 레이블을 통합하는 혁신적인 방법이 포함될 수 있습니다.

비지도 분할: 설문지는 레이블이 지정된 데이터에 의존하지 않고 클러스터링 또는 기타 비지도 학습 방법을 활용하여 뇌종양을 분할하는 새로운 비지도 분할 기술을 제시할 수 있습니다. 이러한 접근 방식은 자동화된 분할 프로세스를 향상시키기 위해 새로운 클러스터링 알고리즘 또는 데이터 기반 분할 전략을 도입할 수 있습니다.

### 3.1. Conventional methods

#### 3.1.1. Thresholding-based technique

### 3.1.1. Thresholding-based technique

Thresholding-based segmentation technique is a fast, easy to implement, and effective conventional segmentation method by comparing their intensities with one or more intensity thresholds. The thresholding-based technique includes the “global thresholding” and a “local thresholding” (Gordillo et al., 2013; Liu et al., 2014; Saman & Jamjala Narayanan, 2019).

#### 3.1.1.1. Global thresholding

In the global thresholding method, the intensity is the best property that pixels in a region can share and depend it to determine the intensity ratio between objects and the background. The global thresholding is a suitable technique for an MR image that contains objects of similar contrast or high intensity between

Thresholding-based technique는 이미지 처리 및 분할에서 널리 사용되는 기술 중 하나입니다. 이 기술은 이미지의 각 픽셀 값을 비교하여 임계값(threshold)과 비교하여 이진화하는 방법을 의미합니다.

1. **Global Thresholding:** 전역 임계값을 사용하여 이미지를 이진화하는 방법으로, 이미지 전체에 동일한 임계값을 적용합니다. 픽셀의 강도가 임계값보다 크면 하나의 값(예: 흰색)으로 설정되고, 그렇지 않으면 다른 값(예: 검정색)으로 설정됩니다.

2. **Local Thresholding:** 지역 임계값을 사용하여 이미지를 이진화하는 방법으로, 이미지의 각 지역에 다른 임계값을 적용합니다. 이는 이미지의 각 부분이 서로 다른 조명 조건 또는 대비를 가질 때 유용합니다.

Thresholding-based technique는 간단하고 효과적인 방법으로 이미지를 처리하고 분할하는 데 사용됩니다. 이를 통해 이미지의 특정 부분을 강조하거나 배경을 제거하여 원하는 객체를 분리하는 데 도움이 됩니다. 이 기술은 뇌 종양 분할과 같은 의료 이미지 처리 분야뿐만 아니라 다양한 이미지 처리 응용 프로그램에서 널리 사용됩니다.

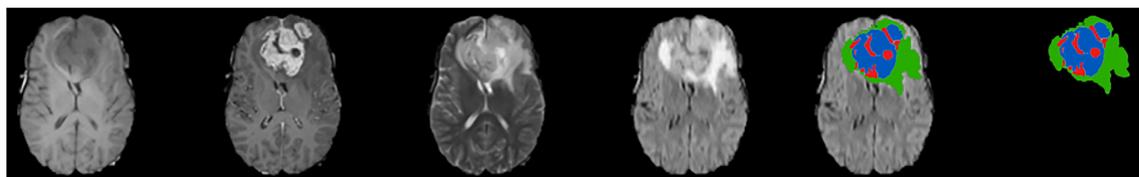


Figure 2: Brain tumor segmentation. From left: T1, T1c, T2, FLAIR, and segmented tumor. In segmented image, blue signal is an active region, red signal is necrotic core, and a green level signal is edema. Images are generated by using BraTS 2019 data.

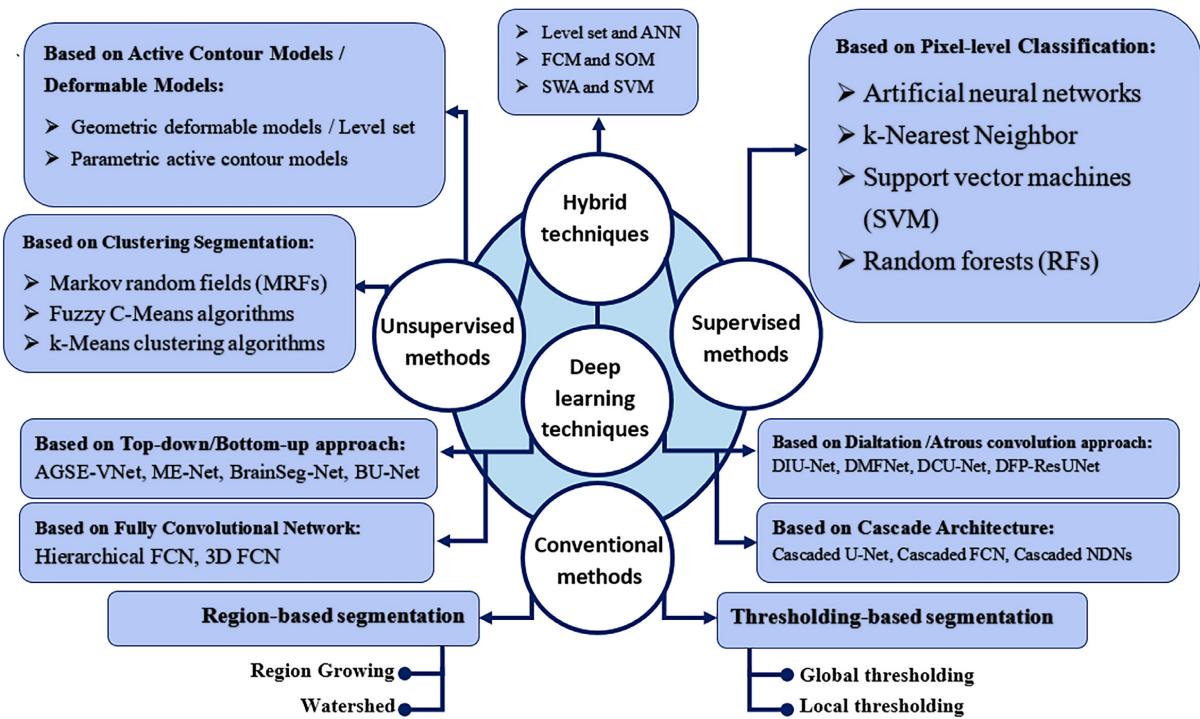


Figure 3: 다양한 원칙에 따라 분류된 일반적인 분할 방법 및 기술을 시각적으로 나타냅니다. 이 그림은 사용자의 개입 정도, 각 범주에서 사용되는 특징 등에 따라 다양한 하위 범주로 나누어진 전통적인 방법, 지도 및 비지도 분할 방법, 그리고 딥러닝 및 혼합 방법을 포함한 분할 기술을 보여줍니다.

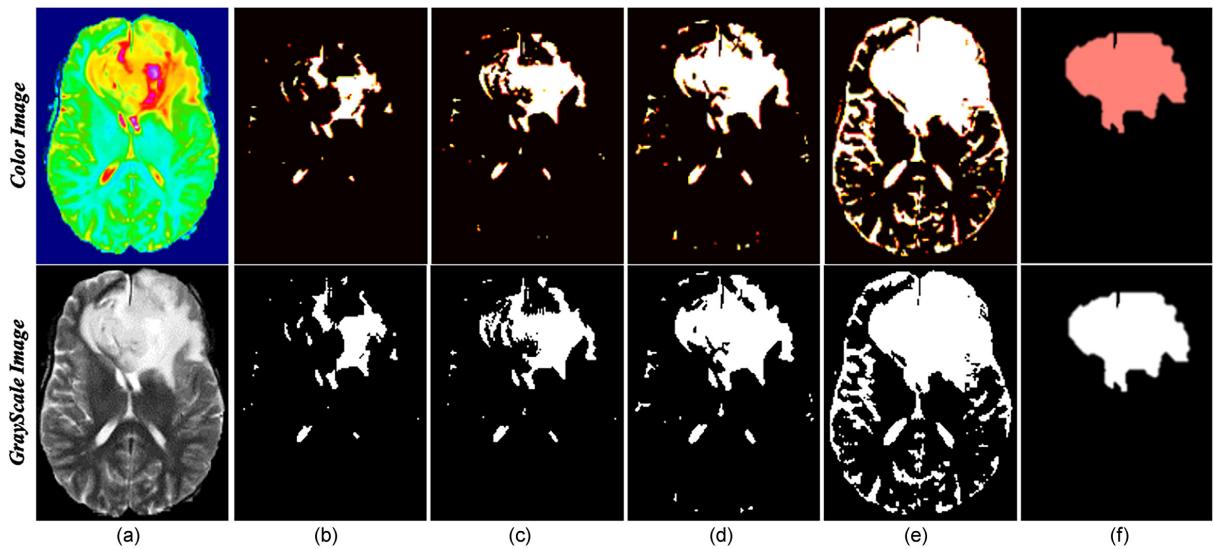
### 3.1.2. Region-based techniques

Region-based segmentation techniques examine pixels in an image and form disjoint regions by integrating the neighborhood pixels with homogeneity properties based on a predefined similarity standard. The region-based technique includes “region growing” and “watershed”.

region growing 과 watershed 방법을 이야기 한다

#### 3.1.2.1. Region growing

영역 기반의 방식에서 가장 많이 사용되는 방식이 **region-growing** 알고리즘이다. 이 방식은 기준 픽셀을 정하고 기준 픽셀과 비슷한 속성을 갖는 픽셀로 영역을 확장하여 더 이상 같은 속성을 갖는 것들이 없으면 확장을 마친다. Dec 20, 2014



a. 인간 뇌종양의 MR 이미지(T2 모달리티)가 표시됩니다. b. 시드 포인트는 수동으로 선택하거나 시드 영역 성장 (SRG) 알고리즘(Adams & Bischof, 1994)을 사용하여 무작위로 선택됩니다. c. 여러 시드 클래스로의 부분 세그멘테이션이 표시됩니다. d. 부드러운 조직, CSF, GM 및 WM을 포함하는 모든 이웃 픽셀을 포함하도록 성장 영역을 점진적으로 확장합니다. e. 더 많은 이웃 픽셀을 포함하기 위해 성장 영역을 더 확장합니다. f. 완료된 세그멘테이션이 얻어지며, 뇌종양 영역만을 나타냅니다.

이 과정은 시드 포인트에서 시작하여 점진적으로 확장하여 뇌종양 영역을 정확하게 캡처하는 방법을 보여줍니다.

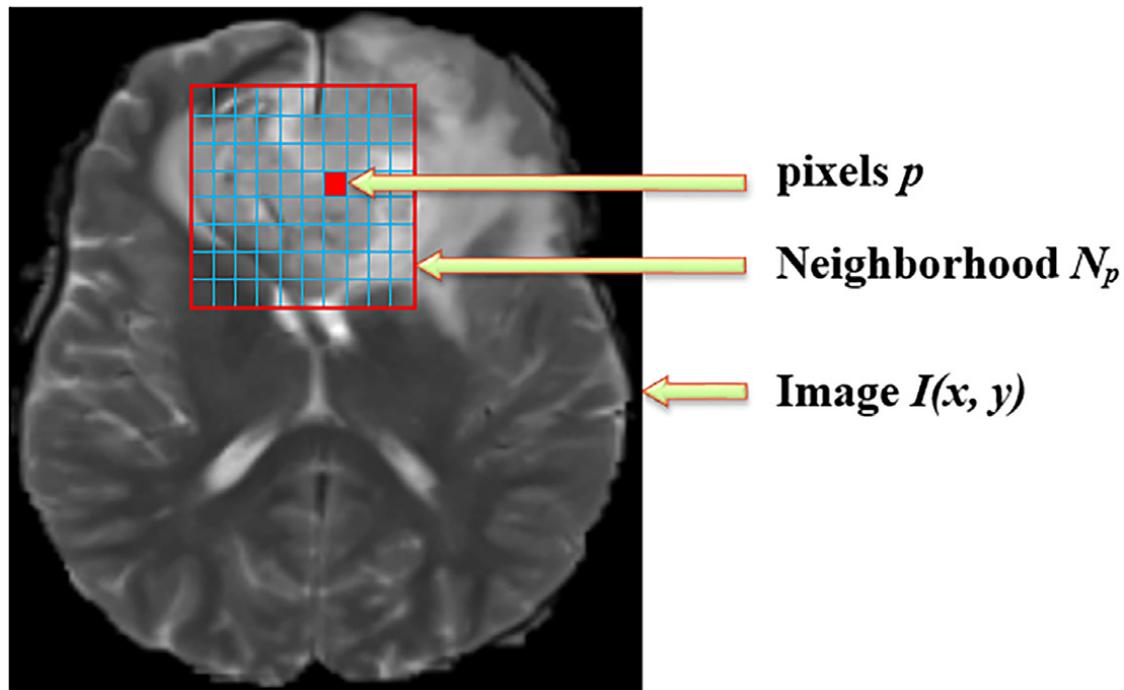


fig 5: 지역 임계값 처리 방법을 보여주는데, 픽셀의 임계값은 전체 이미지가 아닌 지역 이웃의 강도 통계에 기반합니다. 이 방법을 사용하면 이미지의 지역적 특성을 고려하여 보다 적응적인 임계값 처리가 가능해지며 세그멘테이션 정확도를 향상시킬 수 있습니다.

### 3.1.2.2. Watershed

<https://eehoeskrap.tistory.com/87>

WaterShed(워터쉐드) 워터쉐드는 영상 분할 알고리즘 중 하나이다. "Use of Watershed in Contour Detection"이라는 논문에서 1979년 처음 나왔다. 영상의 필셀 값을 2차원 지형으로 생각하고, 위 아래 방향에서 물을 채우는 방식이다.

워터쉐드(Watershed) 분할은 이미지 처리에서 사용되는 영역 기반 기술 중 하나로, 물의 흐름을 모방하여 이미지를 분할하는 방법입니다. 이 아이디어는 물이 지형에서 흐르는 방식에서 영감을 받았습니다. 비 내리는 동안 떨어지는 물방울은 서로 다른 지역의 캐치먼트 분지에 모이게 되는데, 이러한 분지는 서로 다른 계곡과 연관되어 있습니다. 각 지점은 오직 하나의 고유한 분지에 속하며, 물은 각 캐치먼트로 흘러들어가 계곡을 채우기 시작합니다. 이때 서로 다른 캐치먼트에서 나온 물은 섞이지 않고, 만나는 지점에 댐이 건설되어 경계를 형성합니다. 이를 이미지 처리에 적용하면 밝은 픽셀은 산봉우리를 나타내고 어두운 픽셀은 계곡을 나타내며 댐은 이미지 객체의 경계를 나타냅니다. 이를 통해 이미지에서 서로 다른 객체를 분리하고 세분화할 수 있습니다. 워터쉐드 기술은 뇌종양 분할에도 널리 사용되며, 전문가들은 이를 통해 뇌 영상을 효과적으로 분할하고 분석할 수 있습니다.

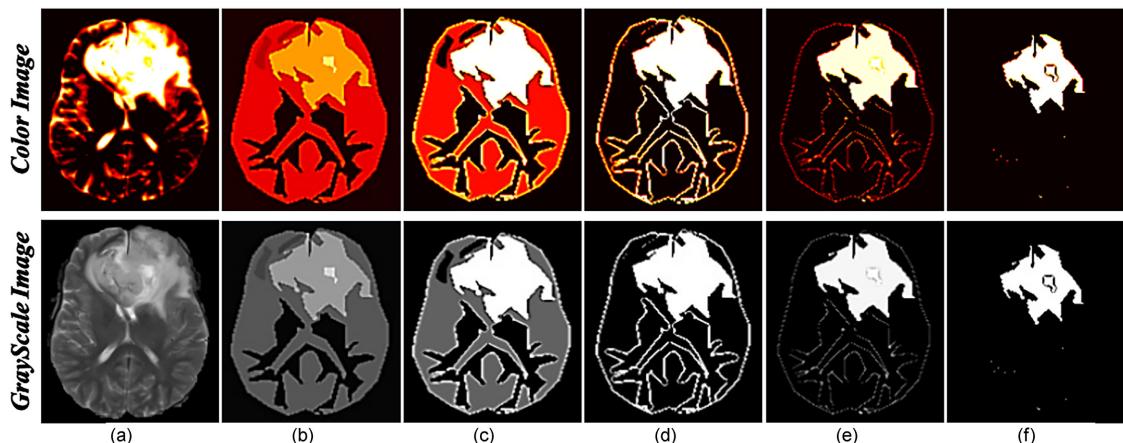


Figure 6: Image segmentation using the watershed technique. (a) Original image T2 modality for a brain tumor, (b) result of a watershed segment operation performed on the original image, and (c, d, and e ) expanding the watershed of the region growing in order to obtain the bright pixels that represent the final segmentation in the image (f).

## 3.2. Supervised methods

### **3.2.1. Segmentation based on pixel-level classification**

대충 지도기반 학습은 과적합이 일어날 수 있다는 내용의 뜻

동일한 훈련 세트를 여러 이미지에 사용할 경우 결과가 편향될 수 있고, 지역 정보를 무시하면 노이즈에 민감해질 수 있습니다. 뇌종양 세분화에서는 주로 인공 신경망(ANN), k-NN, RF 및 SVM과 같은 지도 분류 기술이 사용됩니다.

#### **3.2.1.1. Artificial neural networks**

ANN의 장점:

1. 비선형 관계 및 분포를 모델링할 수 있음
2. 비정형 데이터에 대한 세분화 효과적
3. 계산 능력이 우수하며 전문가 개입이 적음
4. 다양한 시각적 패턴 감지에 널리 사용됨

ANN의 단점:

1. 동일한 훈련 세트를 여러 이미지에 사용할 경우 결과가 편향될 수 있음
2. 지역 정보를 무시하면 노이즈에 민감해질 수 있음
3. 복잡한 모델 구축 및 훈련에 시간과 노력이 많이 필요함

#### **3.2.1.2. K-nearest neighbor**

k-최근접 이웃(k-NN) 알고리즘은 매우 간단하고 구현하기 쉬운 분류 기반 세분화 기술입니다. k-NN의 아이디어는 서로 가까운 비슷한 픽셀 집합의 특징과 일치하는 클래스로 분류된 분리된 픽셀(3D 이미지의 복셀)을 기반으로 합니다. 가장 가까운 미분류 이웃을 찾은 후 해당 이웃들을 사용하여 클래스 또는 레이블을 결정합니다. 시험 지점의 레이블을 예측하기 위해 훈련 사례와 새로운 미분류 테스트 지점 간의 유사성이나 거리를 추정합니다.

k-NN의 장점:

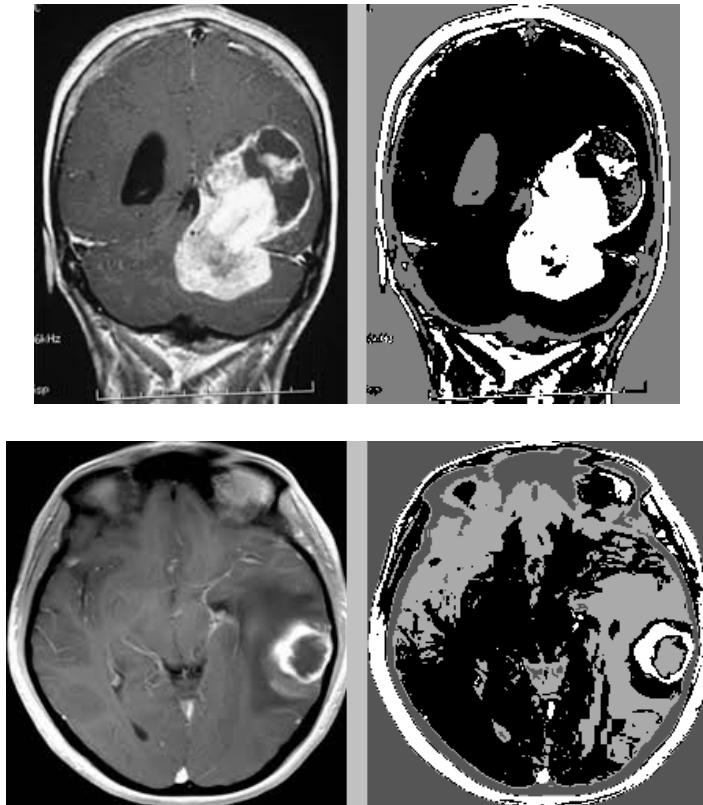
1. 간단하고 직관적인 알고리즘
2. 쉽게 구현 가능
3. 새로운 데이터에 대한 빠른 예측
4. 훈련 단계에서 복잡한 모델 구축이 필요하지 않음

k-NN의 단점:

1. 계산 비용이 높음
2. 데이터의 차원이 증가하면 성능이 저하될 수 있음
3. 이상치에 민감함
4. 훈련 데이터에 대한 저장 공간이 필요함

따라서 k-NN은 간단하고 직관적인 분류 알고리즘으로 빠른 예측이 가능하지만, 대규모 데이터셋이나 고차원 데이터에서는 성능 문제가 발생할 수 있습니다. 또한 이상치에 민감하고 계산 비용이 높은 단점이 있습니다.

<https://github.com/AbhinavUtkarsh/Image-Segmentation>



### 3.2.1.3. Random forest

Random Forest (RF)는 대규모 데이터셋에서 가장 효과적으로 작동하는 간단한 지도 학습 분류 접근 방식입니다. RF는 잡음에 상대적으로 강건하며 변수 손실 없이 더 많은 입력 변수를 지원하며 중요한 분류 기능을 고려합니다. Breiman (2001)에 따르면, "랜덤 포레스트(RF)는 입력  $x$ 에서 가장 인기 있는 클래스에 대해 각 트리가 단위 투표를 하는 독립적으로 동일하게 분포된 랜덤 벡터의 모음으로 구성된 분류기"입니다.

뇌 종양 세분화의 경우, RF는 고차원 특징 벡터, 다중 클래스 분류 문제 및 HGG에 가장 효과적인 방법입니다. Koley et al. (2016)는 종양 영역을 식별하고 추출한 후 패턴 분류를 위해 RF를 사용했습니다. 추출된 병변은 86가지 다른 특성을 사용하여 훈련 데이터셋을 개발하고 이후 분류기에 공급되었습니다. Goetz et al. (2016)는 희소 샘플링으로 인한 샘플 선택 오류를 줄이기 위해 도메인 적응 기술에 의존하는 새로운 RF 기반 접근 방식을 제안했습니다. 제안된 기술은 희소하고 명확한 주석을 사용하여 다양한 조직 클래스에 대한 고품질 분류기를 생성합니다. Soltaninejad et al. (2018b)는 MRI 이미지에서 자동 뇌 종양 세분화를 위한 학습 기반 기술을 제안했습니다. MRI 이미지 복셀은 RF를 사용하여 정상 뇌 조직과 다양한 종양 영역으로 분류됩니다. 환자의 종양 조직의 체적적 특성과 환자 연령을 회귀 기반 RF에 적용하여 환자의 전반적 생존 시간을 예측했습니다. 이 방법의 효과는 MICCAIBraTS 2017 챌린지 데이터셋에서 평가되었습니다.

- 특징 추출:** 먼저 이미지에서 특징을 추출합니다. 이 특징은 이미지의 각 픽셀 또는 영역에서 얻어진 정보로, 분할에 사용될 중요한 정보를 포함합니다.
- 훈련 데이터셋 구성:** 이미지의 각 픽셀 또는 영역에 대한 특징을 사용하여 훈련 데이터셋을 구성합니다. 각 데이터 포인트는 해당 픽셀 또는 영역이 속하는 클래스(예: 종양 영역 또는 정상 조직)를 나타내는 레이블을 포함합니다.
- 랜덤 포레스트 학습:** 랜덤 포레스트는 다수의 의사 결정 트리로 구성됩니다. 각 트리는 무작위로 선택된 특징 부분 집합을 사용하여 학습됩니다. 이는 다양성을 증가시켜 모델의 일반화 성능을 향상시킵니다.
- 예측:** 학습된 랜덤 포레스트 모델을 사용하여 새로운 이미지에 대한 분할을 예측합니다. 각 픽셀 또는 영역은 각 트리에서 얻은 예측을 종합하여 최종 예측을 생성합니다.
- 분할 결과 생성:** 예측된 결과를 사용하여 이미지를 분할하고 각 픽셀 또는 영역을 해당 클래스에 할당합니다. 이를 통해 종양 영역과 정상 조직 등을 구분할 수 있습니다.

<https://medium.com/gradient/using-random-forests-for-segmentation-e4793482f129>

### 3.2.1.4. Support vector machine

- 원리:** SVM은 주어진 데이터를 가장 잘 분류할 수 있는 결정 경계(하이퍼플레인)를 찾는 것에 초점을 둡니다. 이 결정 경계는 데이터를 가장 잘 나누는 초평면으로, 각 클래스를 분리하는 역할을 합니다. SVM은 주어진 데이터를 고차원 특징 공간으로 매핑하여 비선형 문제를 해결할 수 있습니다.
- 이점:**
  - 다중 도메인 분류에 특히 유용하며 이진 분류에 강력한 기술을 제공합니다.
  - 높은 분류 능력을 가지고 있어 뇌종양 세그멘테이션과 같은 작업에 널리 사용됩니다.
  - 뇌종양의 감지, 위치 파악 및 세포 크기 분할을 가능하게 합니다.
- 단점:**
  - 계산적으로 비용이 많이 들며 수학적으로 복잡합니다.
  - 대규모 데이터셋에 대한 학습 및 예측 시간이 오래 걸릴 수 있습니다.
  - 데이터의 비선형성을 처리하기 위해 커널 트릭을 사용하므로 모델의 해석이 어려울 수 있습니다.

SVM를 사용한 뇌종양 세그멘테이션은 Sandabadi et al. (2016), Zhou et al. (2005), Kharrat et al. (2010) 등 의 연구에서 제안되었습니다. 이들은 SVM을 사용하여 뇌종양 영역을 감지하고 분류하는 방법을 제시했습니다. 또한, SVM을 이용한 세그멘테이션 기술은 퍼지 클러스터링 기술보다 우수한 결과를 보여주며, 비선형 분포를 학습할 수 있습니다. 또한, 유전 알고리즘과 SVM을 결합하여 최적의 뇌 조직 특징을 추출하고 종양을 정상, 악성 또는 양성 종양으로 분류하는 하이브리드 방법을 사용했습니다.

이러한 방법은 뇌종양 세그멘테이션에 유용하며, SVM을 통해 정확한 분할 및 분류를 수행할 수 있습니다.

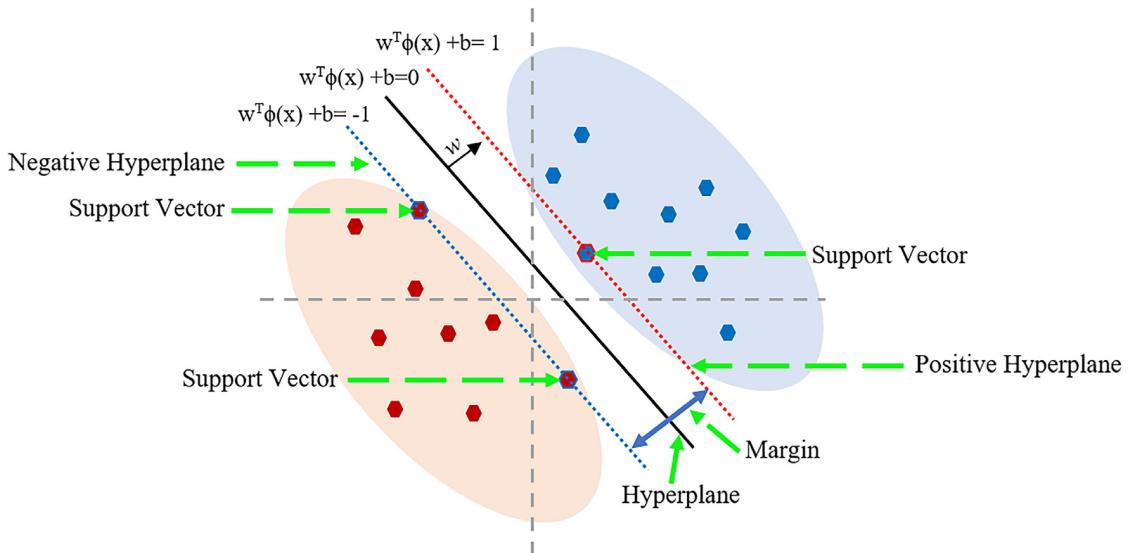


Figure 7: Using SVM to split a set of images into two different classes. The classification is done by getting the hyper-plane based on a kernel function ( $K$ ) that separates the two classes

### 3.2.1.5. Superpixel-based segmentation

슈퍼픽셀 기반 세그멘테이션은 유사한 저수준 속성을 가진 픽셀을 클러스터링하여 시각적으로 의미 있는 개체를 생성하는 기술을 말합니다. 이를 위해 이미지는 간단한 선형 반복 클러스터링(SLIC) 기술을 사용하여 슈퍼픽셀이라고 알려진 작은 영역을 생성하여 세그멘트화됩니다. 이로 인해 슈퍼픽셀은 이미지 내의 많은 픽셀의 복잡성을 줄이고 몇 개의 슈퍼픽셀로 효율적으로 표현할 수 있습니다.

슈퍼픽셀 세그멘테이션 알고리즘은 다양한 분류 기준에 따라 여러 유형으로 분류됩니다. 예를 들어, Achanta et al. (2012)는 슈퍼픽셀 알고리즘을 그래프 기반 및 그래디언트 상승 기반 방법으로 반복 과정에 따라 분류했습니다. 또한, Xu et al. (2014)은 슈퍼픽셀 세그멘테이션 전략을 상향식 및 하향식 알고리즘으로 분류했는데, 이는 생성된 형태 기반 슈퍼픽셀에 기초하여 이루어졌습니다.

이러한 방식은 이미지 처리에서 효율적인 세그멘테이션을 달성하기 위한 방법으로 사용되며, 슈퍼픽셀은 복잡한 이미지를 간소화하여 처리를 용이하게 합니다.

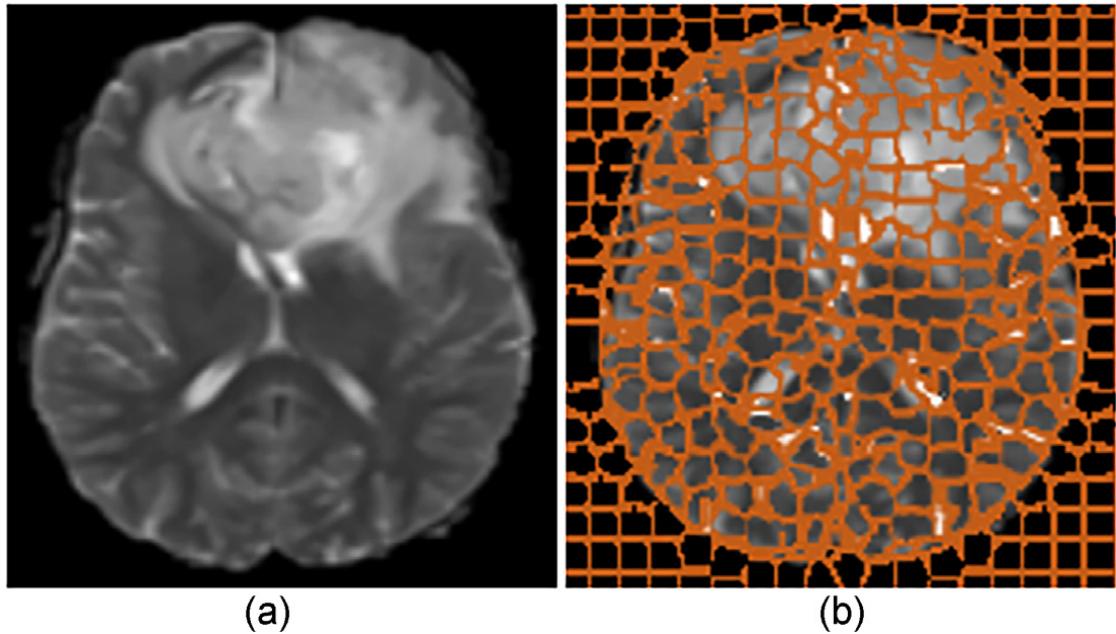


Figure 8: Superpixel segmentation. (a) Original image (T2 modality) and (b) superpixels generated for the original image.

뇌 MRI 이미지에서 슈퍼픽셀을 사용하여 이미지 기본 요소의 수를 줄이고 효율적인 세그멘테이션 결과를 얻기 위해 연구자들이 슈퍼픽셀 접근 방식을 개선했습니다.

Su et al. (2013)는 그래프 스펙트럼 클러스터링 알고리즘을 사용하여 MRI 이미지를 기반으로 슈퍼픽셀을 군집화하여 괴사 및 증강된 종양을 포함한 다양한 범주로 분류하는 방법을 설계했습니다. Alipour 및 Hasanzadeh (2021)는 SLIC를 사용하여 슈퍼픽셀을 생성하고 이를 후속 작업에서 민감도와 계산 비용을 줄이기 위한 원자 단위로 사용했습니다. Soltaninejad et al. (2017)는 FLAIR MRI 이미지에서 각 슈퍼픽셀의 분류를 기반으로 한 슈퍼픽셀 기술을 활용한 뇌종양 세그멘테이션을 위한 완전 자동화된 접근 방식을 제안했습니다. Imtiaz et al. (2020)는 3D MR 이미지에서 추출된 슈퍼픽셀 수준의 특징을 기반으로 한 뇌종양 세그멘테이션 방법을 제시했습니다.

이러한 연구들은 뇌종양 세그멘테이션에 슈퍼픽셀을 적용하여 세분화 과정을 개선하고 뇌종양의 비균질한 세부 경계를 고려하는 데 도움이 되는 방법을 탐구하고 있습니다.

### 3.3. Unsupervised methods

비지도 학습 개념의 클러스터링 기반 세그멘테이션 방법들을 설명

#### 3.3.1. Clustering-based segmentation

클러스터링 기반 세그멘테이션은 레이블이 지정되지 않은 이미지 데이터를 유사한 강도를 가진 픽셀/볼셀의 클러스터로 분할하는 비지도 학습 방법입니다. 이 방법은 특징을 공유하는 유사한 강도를 가진 픽셀/볼셀을 동일한 클러스터에 유지하고 다른 클러스터에는 유사하지 않은 픽셀을 배치합니다.

클러스터링 방법은 일반적으로 하드 클러스터링과 소프트 클러스터링 두 가지 범주로 나뉩니다. 하드 클러스터링에서는 한 픽셀/볼셀이 동일한 특징과 강도를 가진 픽셀/볼셀의 클러스터에만 속할 수 있습니다. 반면 소프트 클러스터링에서는 픽셀/볼셀이 정의된 여러 클러스터 중 두 개 이상에 속할 확률을 제공합니다.

이러한 클러스터링 방법은 데이터를 비슷한 특성을 가진 그룹으로 분류하여 이미지를 세분화하는 데 사용됩니다. 클러스터링은 각 픽셀/볼셀을 서로 다른 그룹으로 나누어 유사성을 기반으로 한 패턴이나 특징을 식별하는 데 도움이 됩니다.

### 3.3.1.1. Density-based clustering

밀도 기반 클러스터링은 이미지 영역에 표현된 픽셀/볼셀의 밀도에 기반하여 생성됩니다. 해당 영역에서 유사한 많은 수의 픽셀로 인해 밀도가 높아지는 지역은 클러스터로 간주됩니다. 밀도 기반 클러스터는 서로 인접한 저밀도의 픽셀 지역에 의해 분리됩니다. 저밀도 지역에 있는 픽셀은 일반적으로 잡음 또는 이상점으로 참조됩니다.

밀도 기반 클러스터링 알고리즘은 다음과 같이 분류됩니다:

(i) 잡음이 있는 응용 프로그램의 계층적 밀도 기반 공간 클러스터링 (HDBSCAN): HDBSCAN은 완전한 밀도 기반 클러스터링 계층 구조를 생성하여 가장 중요한 클러스터만을 추출할 수 있는 단순화된 계층 구조를 제공합니다.

(ii) 잡음이 있는 응용 프로그램의 밀도 기반 공간 클러스터링 (DBSCAN): DBSCAN은 글로벌 밀도 임계값에 기반하여 데이터 객체를 제공할 수 있으며, 이는 계층적이지 않은 평평한 레이블에서 작동합니다. DBSCAN은 거리 메트릭 "Eps"와 "MinPts"라고 불리는 최소 데이터 포인트 양에 기반하여 데이터 포인트를 수집합니다. 그러나 단일 밀도 임계값은 종종 서로 다른 밀도를 가진 일반 데이터 클러스터와 겹치는 클러스터를 올바르게 구분하지 못할 수 있습니다.

(iii) 클러스터링 구조 식별을 위한 점 순서화 (OPTICS): OPTICS는 밀도 기반 접근 방식을 사용하는 클러스터 분석 방법으로, 명시적으로 데이터 객체의 클러스터링을 구성하지는 않습니다. 대신, 데이터의 향상된 순서화를 제공하여 밀도 기반 클러스터링 구조를 나타냅니다. OPTICS는 글로벌 밀도 임계값을 적용하여 평평한 분할을 추출하는 방법을 제안하며, 이는 클러스터가 서로 다른 밀도를 가질 경우 가장 중요한 클러스터로 이어지지 않을 수 있습니다. 또한 OPTICS는 reachability distance RD와 core distance CD에 따라 데이터 객체를 분리하여 데이터 구조를 발견하는 데 사용됩니다.

### 3.3.1.2. k-Means clustering

k-평균 클러스터링은 픽셀 기반 방법 중 기본적인 기술로, 클러스터링에 사용된 거리 측정에 기반하여 입력 데이터를 k개의 클러스터로 분할합니다. 이때, 클러스터 내 유사성은 높지만 클러스터 간 유사성은 낮습니다. 각 클러스터의 평균 강도가 지속적으로 계산되며, 각 픽셀/볼셀을 해당 클러스터의 가장 가까운 중심에 분류하여 이미지를 분할합니다.

k-평균 클러스터링은 계산적으로 매우 비싼 알고리즘으로, k 값의 부적절한 선택의 경우 잘못된 결과를 낼 수 있습니다. 이는 각 반복에서 모든 클러스터의 중심과 모든 데이터 포인트 간의 거리를 계산하기 때문입니다. 이 방법의 목표는 다음과 같은 목적 함수를 최소화하는 것입니다:

$$C_j = \frac{1}{N_j} \sum_{x \in X_j} x, j = 1, 2, \dots, k$$

여기서  $J$ 는 목적 함수를 나타내며,  $\|x(j)i - Cj\|^2$ 는 데이터 포인트  $x(j)i$ 와 클러스터  $Cj$ 의 중심 간의 선택한 거리 측정입니다.  $Cj = 1/Nj \sum_{x \in x_j} x, j = 1, 2, \dots, k$ 는 클러스터의 수를 나타내며,  $n$ 은 데이터 포인트가 해당 클러스터 중심으로부터의 거리를 나타냅니다.

뇌 MRI 이미지에서  $k$ -평균은 회색조 MRI 이미지를 RGB 이미지로 변환하여 가짜 색상 변환을 적용하여 특징을 향상시키는 방법으로 건강한 조직과 종양 조직의 위치를 분리하는 데 사용되었습니다. 또한 Juang 및 Wu (2010)는 뇌 병변 이미지에서 종양을 추적하여 병변의 크기와 위치를 정확히 지정하는 데 도움이 되는 방법을 구현했으며, 매우 희망적인 결과를 얻었습니다. Alam 등 (2019)은 템플릿 기반  $k$ -평균 및 향상된 FCM 알고리즘을 결합하여 MRI 이미지에서 인간 뇌 종양을 식별하는 방법을 제안했으며, 제안된 방법은 회색조 강도에 기반하여 이상 및 정상 조직을 더 잘 감지하는 것으로 나타났습니다. 또한, 이 방법은 이전 방법과 비교하여 뇌 종양을 매우 짧은 시간 내에 감지합니다. Liu 및 Guo (2015)는 뇌 MRI 이미지를 분할하기 위해  $k$ -평균 클러스터링 기술과 SVM을 기반으로 한 전략을 제안했으며, 이 방법은 초기 분류 결과를 얻기 위해  $k$ -평균 클러스터링을 사용하고 각 뇌 조직의 픽셀에 대한 특징 벡터를 선택하여 훈련 및 테스트 샘플로 사용했습니다. 제안된 분할 기술은 더 나은 분할 효과를 얻었습니다.

### 3.3.1.3. FCM clustering

FCM은 MRI 이미지 세그멘테이션 및 뇌종양 분할과 같은 의료 영상 처리 분야에서 널리 사용되는 중요한 기술 중 하나입니다. FCM은 픽셀을 여러 클래스로 분류하고 각 픽셀 단위에 대한 멤버십을 할당하여 픽셀이 두 개 이상의 클래스에 속할 수 있도록 합니다. 또한 FCM 기술은 퍼지 멤버십 함수를 사용하여 다중 클러스터 솔루션을 다룰 때 적응성을 갖습니다.

FCM은  $k$ -평균 클러스터링과 비교하여 겹치는 픽셀에 대해 더 나은 결과를 제공하며, 이미지 데이터를 퍼지 중심 클러스터  $Cj$ 로 분할합니다. 이때, 퍼지 멤버십  $uj, i$ 는 픽셀 간의 거리에 기반하여 계산됩니다. FCM 알고리즘은 뇌종양 분할을 포함한 다양한 조직 클래스로 효과적으로 분할할 수 있도록 도와주며, 퍼지 클러스터링을 통해 부드러운 경계를 가진 등질적인 특징을 식별하는 문제를 해결합니다.

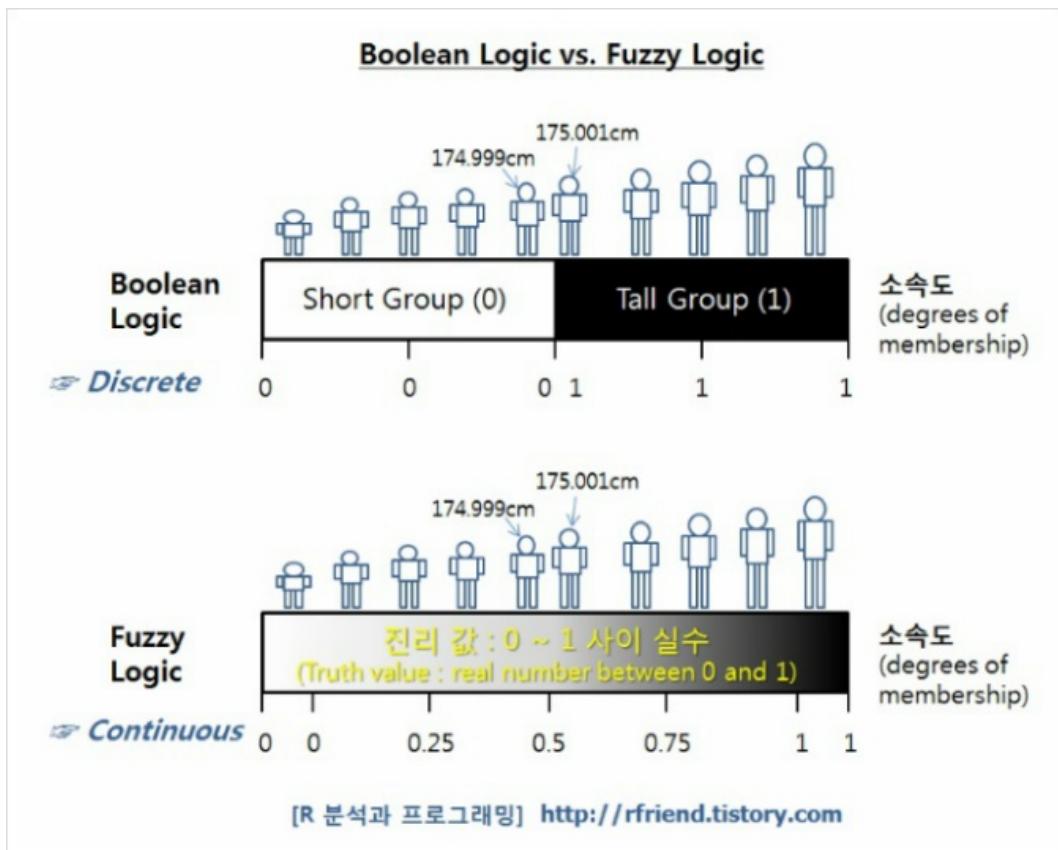
또한, Ganesh et al. (2017)은 향상된 적응형 퍼지  $k$ -평균(EAFKM) 클러스터링 방법을 제안하여 MRI 뇌 이미지를 CSF 공간, GM 및 WM 세 가지 하위 영역으로 분할하는 방법을 제시했습니다. 이 방법은 기존의 FCM 및 AFKM 알고리즈다 보다 더 나은 결과를 제공하며, 이미지를 더 명확하게 보이도록 하는 적응형 클러스터링 프로세스를 제공합니다.

따라서, FCM은 MRI 이미지 처리에서 중요한 역할을 하는 클러스터링 기술이며, 퍼지 멤버십을 사용하여 다양한 의료 영상 분석 및 분할 작업에 적합한 유연성을 제공합니다.

Fuzzy를 영어사전에서 찾아보면 '애매 모호함'이라는 뜻입니다. (뜻이) (be) vague (idea), obscure, fuzzy, inexplicit, puzzling, ambiguous (meaning), hazy (notion), dim (memory), doubtful, evasive, equivocal, elusive Fuzzy Set Theory,

Fuzzy Logic은 '애매 모호한 대상을 다루는 논리'입니다. 고전 논리 연산(Boolean Logic)에서는 1(참, Truth) 아니면 0(거짓, False), 모 아니면 도, 아군 아니면 적군으로 단순 명쾌하게 구분을 합니다.

반면에 Fuzzy 논리(Fuzzy Logic)에서는 진리값(Truth Value)이 0~1 사이의 실수값(real number between 0 and 1)으로 확장하여 소속도(degrees of membership)에 대한 애매모호한 정도, 가능성의 정도(degrees of possibility)를 표현합니다.



<https://rfriend.tistory.com/230>

### 3.3.1.4. Markov random field

마르코프 랜덤 필드(MRF)는 이미지 처리에서 사용되는 확률적 그래픽 모델로, 1975년에 Besag에 의해 처음 소개되었고 1984년에 Geman 및 Geman에 의해 이미지 처리 응용을 위해 발전되었습니다. MRF는 문맥, 강도, 질감, 스펙트럴 특성 및 공간 정보와 같은 다양한 이미지 기능을 클러스터링 프로세스에 효과적으로 통합하여, 이미지 분할에서 널리 사용되며 겹치는 문제 및 클러스터링 결과에 미치는 잡음 효과와 같은 문제를 해결하는 기술로 사용됩니다.

뇌 종양 분할과 관련하여, MRF는 이미지 픽셀 간의 공간 의존성을 표현하고 이웃하는 픽셀 간의 관계를 모델링하는데 사용됩니다. 지역을 뇌 종양 또는 비 종양으로 분류함으로써 MRF는 이웃하는 픽셀이 동일한 지역(종양 또는 비 종양)에 속하는지를 평가합니다. 조건부 랜덤 필드(CRF)는 또한 순차 데이터를 분할하고 레이블링하기 위한 확률적 모델을 개발하는 데 사용되어 뇌 종양 분할과 같은 작업에서 높은 정밀도를 제공합니다.

MRF의 핵심 개념은 격자 상의 레이블 필드로, 이를 MRF로 간주하기 위해 특정 조건을 따라야 합니다. 이 조건은 이웃하는 픽셀이 유사한 레이블을 가질 확률을 포함합니다. MRF의 에너지 함수는 가능한 레이블 필드 공간에서 에너지 함수를 최소화하여 최상의 예측을 결정합니다.

MRF의 단점을 극복하기 위해 Ahmadvand 등(2017)과 같은 연구자들은 MRF 모델과 워터셰드 분할 기술을 결합한 혁신적인 솔루션을 제안했습니다. 이러한 결합은 계산 시간을 줄이고 분할 정확도를 향상시켜 MRI 이미지 분할에서

성공을 거두었습니다. Capelle 등(2000) 및 Yousefi 등(2012)와 같은 다른 연구들도 분할 작업에서 MRF의 사용을 탐구하여 다양한 응용 분야에서의 효과를 입증했습니다.

요약하면, MRF는 이미지 분할에서 강력한 기술로, 특히 MRI 뇌 분할에서 공간 의존성을 모델링하고 이미지 픽셀 간의 복잡한 관계를 처리하여 뇌 종양 분할과 같은 작업에서 보다 정확한 분할 결과를 제공합니다.

<https://www.youtube.com/watch?app=desktop&v=62fSRkK3-Ao>

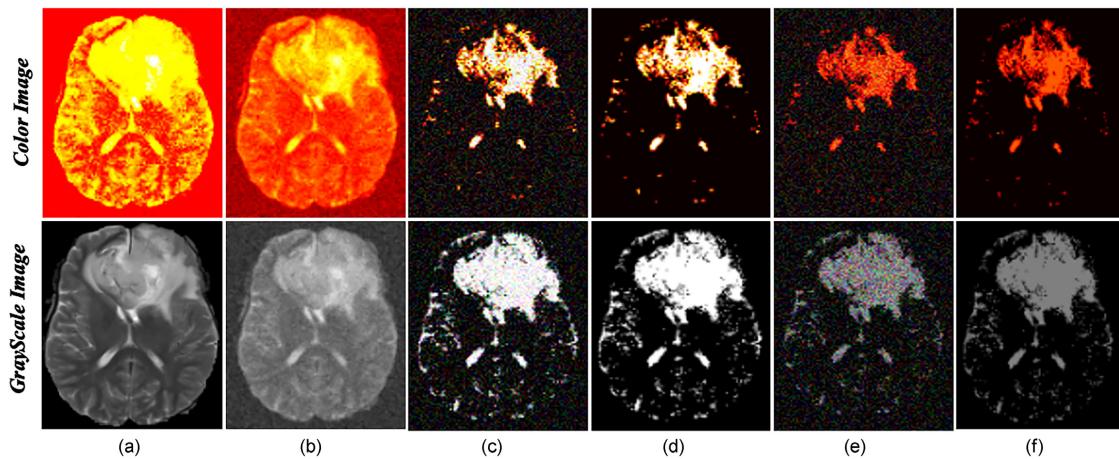


Figure 9: MRF segmentation of a brain tumor. From left:

- (a) An MR image T2 modality of a human brain tumor,
- (b) noisy image,
- (c) naive Bayes image with noisy,
- (d) naive Bayes image without noisy,
- (e) MRF image with noisy, and
- (f) MRF image without noisy.

### 3.3.2. Active contour models/deformable models

활동적 윤곽 모델/변형 모델은 2D MRI 이미지를 분할하여 뇌 종양 경계를 추출하는 데 큰 성공을 거두었습니다. 이러한 모델 기반 분할 기술은 대부분 3D 이미지 분할에 사용되며, 기하학적 변형 모델 및 매개 변수 변형 모델로 사용됩니다. 이 모델들은 특정 해부 구조에 대한 연결된 연속 모델을 구축하여 객체의 모양, 위치 및 방향과 같은 사전 지식을 통합합니다.

<https://nuguziii.github.io/survey/S-002/>

### 3.3.2.1. Parametric active contour models

Parametric active contour 모델은 뇌종양 분할 응용 프로그램에서 널리 사용되며 생물학적 구조의 다양성을 적응하고 MRI 이미지에서 해부 구조를 효과적으로 분할하고 추적하는 능력을 갖추고 있습니다. 이러한 모델은 이미지 데이터 제약 조건과 구조의 크기, 위치 및 모양에 대한 사전 지식을 활용하여 객체 경계를 정확하게 파악할 수 있습니다.

1. **능력과 적응성:** Parametric active contour 모델은 생물학적 구조의 다양성을 수용할 수 있어 MRI 이미지에서 해부 구조를 분할하고 추적하는 데 적합합니다. 이미지 데이터 제약 조건과 사전 지식을 활용하여 이러한 모델은 객체 경계를 효과적으로 포착할 수 있습니다.
2. **부드러운 모양 정의:** Active contours는 닫힌 곡선으로 표현되며 이미지 내에서 부드러운 모양을 정의하고 객체 경계를 추적하기 위해 모델을 변형시킵니다. 이 변형 과정은 전역 및 지역 힘에 영향을 받으며 곡선의 탄성과 견고성을 제어하는 특정 에너지 함수를 줄이는 데 도움이 됩니다.
3. **전역 및 지역 힘:** 전역 힘은 곡선을 원하는 경계로 이동시키는 데 도움을 주고, 지역 힘은 변형 과정 중에 모델의 부드러움과 유연성을 보장합니다. 의도한 경계 근처에서 곡선을 올바르게 초기화하는 것이 분할 과정 중 로컬 미니마를 피하는 데 중요합니다.
4. **변형 가능한 Active Contour 모델:** 변형 가능한 active contour 모델은 이미지 내의 점 모음을 연결하여 에너지 함수를 최소화하는 곡선입니다. Active contour 함수의 전역 에너지는 가장자리에서 0이고 균질한 영역에서 양수이며 경계 감지를 돋습니다.
5. **도전과 해결책:** Active contours는 날카로운 모서리와 오목한 부분이 있는 회색조 이미지에서 잘 작동하지 않을 수 있지만, Xu와 Prince가 제안한 그래디언트 벡터 플로우(GVF)가 이 한계를 극복했습니다. GVF는 일관된 결과를 위해 객체에 대한 사전 지식과 신중한 매개 변수 선택뿐만 아니라 복잡한 계산을 필요로 합니다.
6. **민감성과 효율성:** Active contour 변형 모델은 뇌종양의 경계를 감지하는 데 높은 민감성을 보여 전통적인 가장자리 감지 방법을 능가합니다. Active contours의 적응성과 정확성은 특히 뇌종양 분석에서 매우 중요한 도구로서 의료 이미지 분할 작업에서 가치가 있습니다.

요약하면, parametric active contour 모델은 의료 이미지에서 해부 구조를 분할하는 강력한 프레임워크를 제공합니다. 이미지 제약 조건, 사전 지식 및 전역/지역 힘을 활용하여 이러한 모델은 높은 민감성과 정확성으로 객체 경계를 정확하게 파악할 수 있습니다.

<https://www.intechopen.com/chapters/59741>

Parametric active contour model 을 이용한 세그멘테이션 관련 논문

<https://jade314.tistory.com/entry/SnakeActive-Contour-ModelsACM>

한국어 자세한 설명

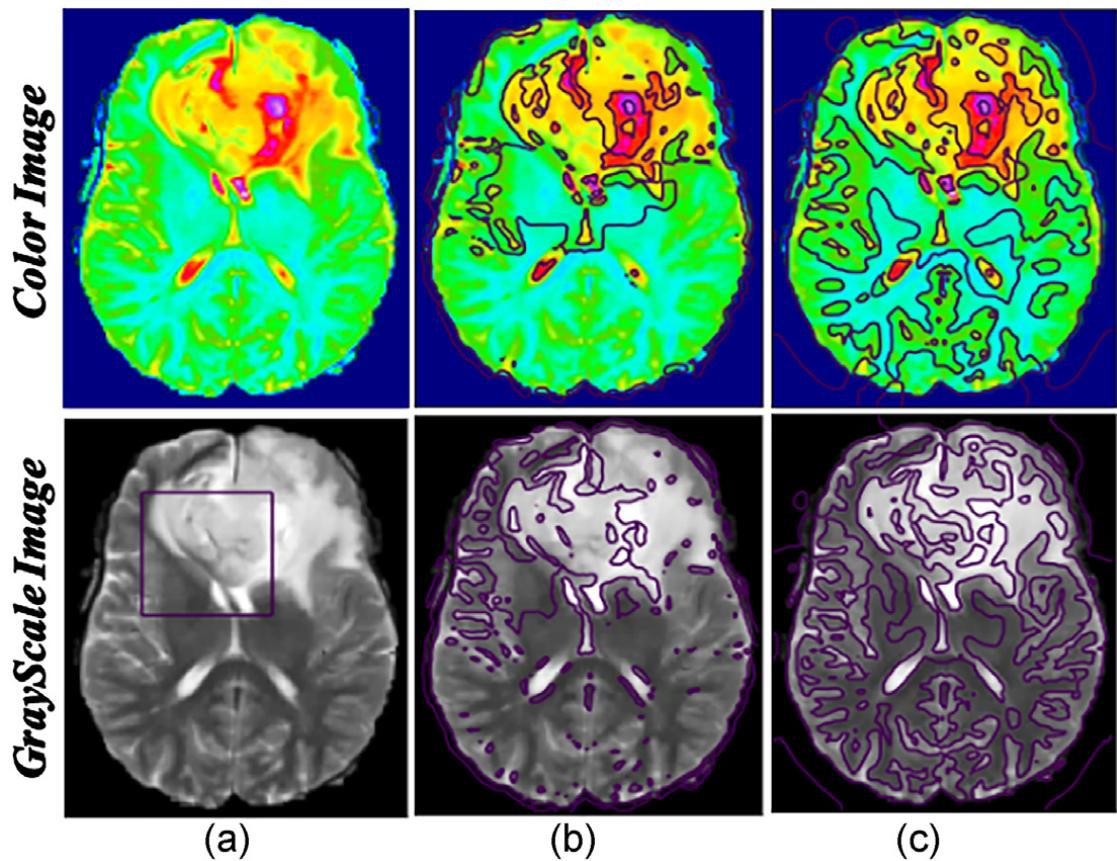


Figure 10: Segmentation of brain MRI image (T2 modality) using active contour.

### 3.3.2.2. Geometric deformable models or level sets

기하학적 변형 모델 또는 레벨 세트는 볼륨형 3D 이미지 세그멘테이션에서 매개 변수 기하학적 변형 모델을 사용할 때 나타나는 분할 및 병합 윤곽의 위상 변화에 대한 어려움을 해결하기 위해 개발되었습니다. 이러한 모델은 커브 진화 이론과 레벨 세트 방법을 기반으로 합니다. 이러한 방법은 활성 매개 변수 윤곽을 초기화하는 데 성공했지만, 많은 세그멘테이션 방법이 정형적으로 모양이 있는 객체와 노이즈가 있는 이미지를 처리할 수 없어 MRI 이미지의 종양 세그멘테이션에서 어려움을 겪습니다.

기하학적 변형 모델은 MRI 이미지 세그멘테이션에 일반적으로 사용되며 이미지 내에서 단일 객체를 찾습니다. 기하학적 변형 모델을 사용한 MRI 이미지 세그멘테이션에 대한 여러 접근 방식이 제안되었지만, 그 유효성은 심각하게 제한됩니다.

Ho et al. (2002)은 3D MRI 이미지에서 종양의 해부 구조를 자동으로 분할하기 위한 방법을 개발했습니다. 종양 영역과 배경에 대한 확률을 결정하기 위해 레벨 세트 스네이크 전파를 안내하는데 사용되었습니다. 이 방법은 전파 용어를 부호화된 지역 통계력으로 변조하여 약한 부분이나 누락된 가장자리 부분을 통해 스네이크가 누출되는 것을 방지하여 안정된 해결책을 제공합니다.

Li et al. (2008)은 뇌 MRI 세그멘테이션을 위한 지역 기반 액티브 컨투어 모델을 제안했습니다. 이 모델은 지역 영역에서 강도 정보를 활용하며 변량 레벨 세트 공식을 사용합니다. 이들은 컨투어에 대한 데이터 적합한 에너지를 결정

하고 컨투어 양쪽의 이미지 강도를 지역적으로 근사하는 두 함수를 결정했습니다. 이 에너지를 정규화 항과 함께 변량 레벨 세트 공식에 통합한 후, 에너지 최소화를 위한 커브 진화 방정식을 유도했습니다.

Bogovic et al. (2013)은 객체 관계와 위상을 보장하며 갭이나 중첩을 제거하고 경계별 속도를 허용하며 객체 수에 독립적인 계산 효율적인 성장 방식을 제공하는 기하학적 변형 모델을 기반으로 한 다중 객체 세그멘테이션 방법을 제안했습니다.

<https://www.youtube.com/watch?v=B205e9EEyFk>

- 위에서 설명한 Parametric active contour models 과 유사한 개념의 방식인거같다
- 특정 에너지 함수를 최소화하는 방향으로 어떤 라운드한 테두리를 띠는 기법인듯
- 영상의 6분 40초 부터 어떤 개념의 알고리즘인지 파악할 수 있다

### 3.4. Hybrid techniques

의료 이미지 분할에서의 혼합 기술은 여러 방법을 결합하여 그들의 강점을 활용하고 분할 정확도를 향상시키는 것을 의미합니다. 이러한 조합은 더 신뢰할 수 있는 결과를 얻을 수 있으며, 특히 뇌 MRI 분할과 같이 복잡한 응용 프로그램에서 유용합니다.

Parveen과 Singh (2015)은 뇌 종양 영역의 정확한 분류를 위해 SVM(Support Vector Machine)과 FCM(Fuzzy C-Means)을 통합한 혼합 기술을 제안했습니다. 먼저 이미지 대비 향상 기술이 적용되었으며, 이후 이 중 임계값 및 형태 연산을 사용하여 두개골을 제거했습니다. 그런 다음 FCM 클러스터링을 사용하여 뇌 MRI 이미지에서 의심되는 영역을 분할했습니다. MRI 이미지에서 특징을 추출하기 위해 회색조 런 길이 행렬을 사용하고, 그 후 SVM을 사용하여 뇌 MRI 이미지의 분류를 더 정확하고 효율적으로 수행했습니다.

Akselrod-Ballin 등(2006)은 MRI에서 뇌 구조를 식별하기 위한 SVM 기반 분류와 다중 스케일 분할 가중치 집계를 통합한 혼합 기술을 소개했습니다. 이 방법은 불규칙한 피라미드로 표현된 완전한 계층 구조를 생성하여 다양한 스케일에서 해부학적 구조를 감지할 수 있도록 했습니다.

Nyma 등(2012)은 MRI 이미지 분할을 위해 Otsu 임계값 처리와 FCM을 결합한 혼합 기술을 제안했습니다. Otsu 임계값 처리는 초기 굵은 분할에 사용되어 동질적인 영역을 감지한 후, FCM을 사용하여 뇌 MR 이미지를 여러 세그먼트로 분할했습니다.

Vaibhavi와 Rupal(2018)는 뇌 종양 분할을 위해 k-means와 FCM 알고리즘을 결합한 혼합 기술을 제안했습니다. 결과는 개별 FCM 및 k-means 알고리즘의 결과와 비교되어 혼합 접근 방식의 효과를 평가했습니다.

Hamad 등(2019)은 MRI 이미지에서 뇌 종양을 감지하기 위해 FCM과 임계값 접근 방식을 결합한 혼합 기술을 개발했습니다. 이 방법은 잡음 제거에 중점을 두었으며, 균형 대비 기술을 사용하여 이미지 대비를 향상시켰습니다. FCM은 정상 뇌 영역을 분할하는 데 사용되었고, 임계값 접근 방식은 향상된 이미지를 이진 이미지로 변환하여 MRI 이미지에서 종양 영역을 분할했습니다. 그런 다음 Canny 엣지 감지 방법을 사용하여 세밀한 가장자리를 감지했습니다.

Zhang 등(2019a)은 뇌 종양 분할을 위해 k-means++와 FCM 알고리즘을 모폴로지 연산과 결합한 혼합 클러스터링 기술을 제안했습니다. 모폴로지 연산을 사용하여 MR 뇌 이미지에서 비뇌 조직을 제거하여 노이즈 민감도를 줄였습니다.

습니다. k-means++ 알고리즘은 과적합을 방지하기 위해 클러스터 중심의 결정적 초기화에 사용되었고, 가우시안 커널 기반 FCM을 사용하여 클러스터링을 수행하여 분류 능력을 더욱 향상시켰습니다.

이러한 혼합 기술은 다양한 분할 방법을 결합하여 뇌 MRI 분할의 정확도와 효율성을 향상시키는 데 효과적임을 보여 줍니다.

## 3.5. Deep learning techniques

최근 몇 년간 의료 이미지 분석에서 이미지 분할은 일반적인 작업이 되었으며, 심층 학습 기술에 의해 촉진되었습니다. 현재, CNN(Convolutional Neural Networks)을 기반으로 한 심층 학습 기술을 사용한 뇌 종양 분할은 연구자들의 관심사 중 하나로, 종양 영역을 정확하게 결정하는 작업을 향상시키는 정확한 분할 방법을 얻기 위해 진행되고 있습니다. 최근에는 뇌 종양 분할을 위해 여러 CNN 기반 접근 방법이 제안되었습니다. 이 절에서는 각 구조에서 사용된 가장 중요한 특징을 기반으로 최근의 CNN 기반 분할 모델의 구조적 세부 사항이 제시됩니다.

### 3.5.1. Based on fully convolutional network approach

Fully Convolutional Network (FCN) 접근 방식은 Long 등(2015)에 의해 제안되었으며, 이 방식은 기본 CNN의 분류기 레이어를 밀집 FCN 레이어로 전환하여 완전히 연결된 레이어(밀집 레이어)를  $1 \times 1$  합성곱 레이어로 대체합니다. FCN은 주로 지역 정보에 기반한 표현을 학습하려고 시도하지만, 이미지의 전역 의미론적 맥락을 잃어버리기 때문에 분할이 상당히 모호해집니다. 따라서, VGG-16과 같은 기본 모델은 FCN 모델이 분할을 위한 최종 레이어에서 저층 및 고층 특징을 병합하기 위해 스kip 연결을 사용하여 효과적인 결과를 달성하는 데 도움이 되었습니다.

Sun 등(2021)은 MRI 이미지에서 글리오마 분할을 위해 FCN을 기반으로 한 다중 경로 3D 아키텍처를 제안했습니다. 이 아키텍처는 각 경로에서 3D 확장된 컨볼루션을 사용하여 다중 모달 MRI 이미지에서 특징 맵의 서로 다른 수용 영역을 추출하고, 그런 다음 스kip 연결을 사용하여 공간적으로 융합합니다. 이 아키텍처는 FCN 모델이 종양 영역 경계를 더 잘 파악하는 데 도움이 될 수 있습니다.

### 3.5.2. Based on cascaded CNN approach

Havaei et al. (2017) 및 Hussain et al. (2017)에 따르면, 다른 CNN의 서로 다른 수준에 직접 입력을 제공함으로써 다중 규모 예측을 별도로 수행하는 이러한 접근 방식을 개선합니다. 이는 이러한 다중 규모 예측을 별도로 수행하는 이중 경로 방법과 같은 접근 방식을 개선합니다. 여기서 문맥 정보는 입력 연쇄를 통해 추가 이미지 채널로 다른 CNN에 연결됩니다.

Havaei et al. (2017)에 따르면, 로컬 경로를 연결하는 캐스케이드 아키텍처는 첫 번째 CNN의 출력이 두 번째 CNN의 첫 번째 숨겨진 레이어 출력과 연결됩니다. 다른 형태의 캐스케이드 아키텍처는 계층적 하위 영역 분할 연결(Periera et al., 2017; Wang et al., 2017a, 2019a)에 의존합니다. 이 아키텍처에서 뇌 종양 하위 영역은 다중 클래스 분할 문제를 이진 분할 작업의 여러 단계로 분해하여 순차적으로 분할됩니다. 따라서 이 아키텍처는 뇌 종양 하위 영역의 계층적 성격을 활용하여 거짓 양성의 수를 줄이고 클래스 불균형 문제의 영향을 줄입니다.

Wang et al. (2017a)는 뇌 종양의 하위 영역을 순차적으로 분할하기 위해 세 가지 계층적 네트워크를 제안했습니다. 첫 번째 네트워크(WNet)는 다중 모달 MRI 이미지에서 전체 종양을 분리하여 전체 종양의 경계 상자를 얻기 위해 사용되며, 이는 그 후 두 번째 네트워크(TNet)에 입력으로 사용되어 종양 핵을 분할합니다. 두 번째 네트워크의 출력은 종양 핵의 경계 상자이며, 이는 세 번째 네트워크(ENet)에 입력으로 사용되어 강화된 종양을 분할합니다. 이 작업은 Wang et al. (2019a)에서 확대되었으며, 시험 시간 증가를 활용하여 분할 결과의 불확실성 추정 및 후처리를 위한 CRF를 획득합니다. 또한, 파이프라인 분할의 효과를 확인하기 위해 더 많은 제거 실험을 수행합니다.

Jiang et al. (2020)은 뇌 종양의 하위 구조를 세분화하기 위해 두 단계의 캐스케이드 네트워크를 제안했습니다. 첫 번째 단계에서는 U-Net의 변형을 사용하여 굵은 예측을 훈련합니다. 두 번째 단계에서는 두 개의 디코더를 사용하여 네트워크를 확장하여 성능을 향상시킵니다. 이는 초기 예측 맵과 원본 입력을 연결하여 자동 컨텍스트를 사용하여 예측 맵을 개선합니다.

- 캐스케이드란

Cascading이란 여러 개의 classifier를 concat하는 방식의 양상을 학습의 한 종류이다. 이때 어떤 방식을 활용하는가하면 이전 단계 classifier의 결과값에서 얻은 모든 정보를 종속적으로 다음 단계의 classifier의 추가 정보로 활용하는 것이다. Adaboost 알고리즘이 전형적인 cascaded classifier라고 할 수 있다.

### Cascade R-CNN

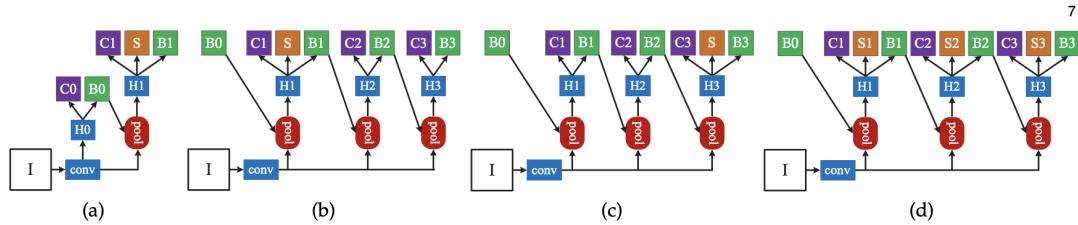
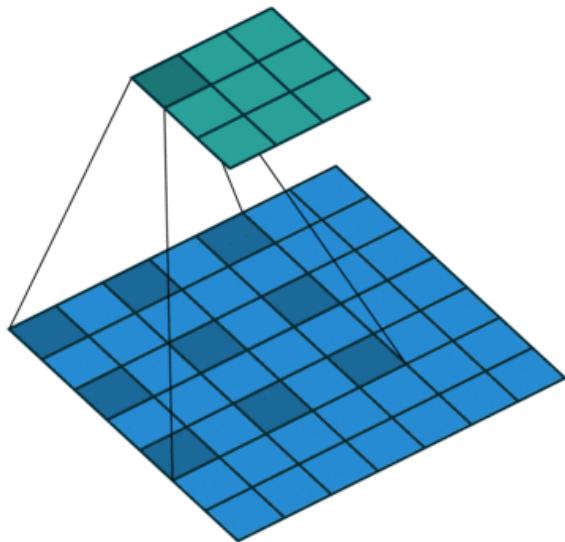


Fig. 6: Architectures of the Mask R-CNN (a) and three Cascade Mask R-CNN strategies for instance segmentation (b)-(d). Beyond the definitions of Fig. 3, “S” denotes a segmentation branch. Note that segmentations branches do not necessarily share heads with the detection branch.

cascade r-cnn은 proposal의 정확도가 향상될 수록 전체 detector의 성능 또한 높아짐을 주장하며, 낮은 IoU에서 학습된 detector의 proposal을 이용해서 매 단계 학습을 점진적으로 해나가는 프로세스를 제안한다. 이 경우도 역시 낮은 IoU에서 학습된 detector의 output 값을 활용해서 다음 단계의 detector 학습에 반영을 하는 구조로 cascading을 활용했음을 알 수 있다.

### 3.5.3. Based on dilated/atrous convolution approach



확장 컨볼루션(또는 atrous convolution) 접근 방식은 Yu와 Koltun(2015)에 의해 제안된 고전적인 CNN의 수정 버전으로, 해상도 손실 없이 분할을 개선하기 위해 다중 스케일 문맥 정보를 체계적으로 수집합니다. 일반적인 피라미드형 CNN과 대조적으로, 확장된 접근 방식은 수용 영역의 지수적인 증가와 공간 정보의 손실 없이 선형 매개 변수 증가를 허용하여 동일한 매개 변수로 표준 컨볼루션보다 입력 데이터로부터 더 효과적인 특징을 생성할 수 있습니다. 확장된 기반 모델의 장점은 밀집한 예측을 제공하기 위해 이미지의 공간 해상도를 보존한다는 것입니다. 그러나 확장된 컨볼루션의 사용은 이미지 픽셀을 전역 컨텍스트에서 분리하여 잘못된 분류에 취약하게 만듭니다.

Chen et al. (2019)은 실시간으로 밀도 있는 체적 분할을 달성하기 위해 다중 파이버(MF) 및 확장된 다중 파이버(DMF) 유닛을 사용하는 매우 효율적인 3D DMFNet을 제안했습니다. 이 네트워크는 MF 유닛을 바탕으로 영감을 받은 3D DMF 유닛을 활용하여 뇌 종양 분할의 계산 비용을 크게 줄이면서도 높은 정확도를 유지합니다. DMF 유닛의 주요 구성 요소는 다음과 같습니다:

(i) "채널 그룹화", 채널 그룹화 아이디어는 주로 특징 맵과 커널 간의 연결을 줄이고 컨볼루션 채널을 여러 그룹으로 분할하여 매개 변수를 제공하는 것에 의존합니다;

(ii) "멀티플렉서"는 파이버 간의 정보 교환을 용이하게 하기 위해; 그리고

(iii) "확장된 파이버"는 해당 영역을 확대하고 뇌 종양 병변의 다중 스케일 3D 공간 상관 관계를 포착하기 위해 사용됩니다.

Cahall et al. (2021)은 U-Net을 기반으로 한 DIU-Net 아키텍처를 제안하여 뇌 종양 분할을 위한 엔드 투 엔드 아키텍처를 구축했습니다. 이 아키텍처는 수축 및 확장 경로 모두에서 인셉션 모듈과 확장된 컨볼루션을 결합하여 지역적인 구조적 정보와 전역적인 문맥 정보를 추출합니다. 이 아키텍처에서 각 확장된 인셉션 모듈은  $I = 1, 2$  및  $3$ 인  $I$ -확장된 컨볼루션 필터가 뒤따릅니다.

Yang et al. (2020)의 다른 연구에서는 전통적인 U-Net을 기반으로 한 확장된 컨볼루션을 사용한 새로운 아키텍처인 DCU-Net을 제안했습니다. 이미지 해상도를 유지하면서 특징 수용 영역을 확장하기 위해 다운샘플링 경로 끝에 맥스 풀링을 확장된 공간 피라미드 풀링으로 대체합니다. 네트워크가 종양 특징을 더 정확하게 식별할 수 있도록 스킵 연결과 확장된 컨볼루션 잔여 블록을 훈련 네트워크에 결합합니다.

- dilated 컨볼루션 방식을 사용하며
- 맥스풀링을 spp 같은 피라미드 풀링으로 대체했고
- 스킵연결과 잔차학습이 되었다고 추측 (잔차학습은 v-net에 개념이 나올듯)

ability to identify tumor features more accurately, both skip connections and dilated convolution residual blocks are combined in the training networks.

### 3.5.4. Based on the top-down/bottom-up approach

분할 아키텍처의 상향식/하향식 접근 방식은 주로 두 단계로 구성됩니다:

다운샘플링(인코더) 단계와 업샘플링(디코더) 단계입니다.

다운샘플링 단계에서는 이미지로부터 특징을 추출하고, 합성곱 및 풀링 레이어를 통해 이미지 차원을 줄여 저해상도 특징 맵을 얻습니다.

그런 다음 업샘플링 단계에서는 역방향으로 작용하여 디컨볼루션 레이어를 사용하여 이미지 차원을 증가시켜 원하는 클래스의 지역화를 생성합니다.

중간 특징 맵이나 언플링 레이어를 통합하여 최종 결과물의 해상도를 향상시킬 수 있습니다.

분할을 위한 상향식/하향식 접근 방식을 기반으로 한 중요한 아키텍처로는 U-Net 아키텍처와 V-Net 아키텍처 등이 있습니다.

이러한 아키텍처들은 뇌 종양 분할을 위해 변형 및 개선되어 왔으며, Zhang 등(2021)이 제안한 ME-Net이나 Guan 등(2022)이 제안한 3D AGSE-VNet과 같은 아키텍처들이 세분화 정확도를 향상시키기 위해 스kip 연결을 활용하거나 스퀴즈 앤 익사이트(SE) 및 어텐션 가이드 필터(AG)와 같은 모듈을 통합하여 정보 처리와 분할 정확도를 개선합니다.

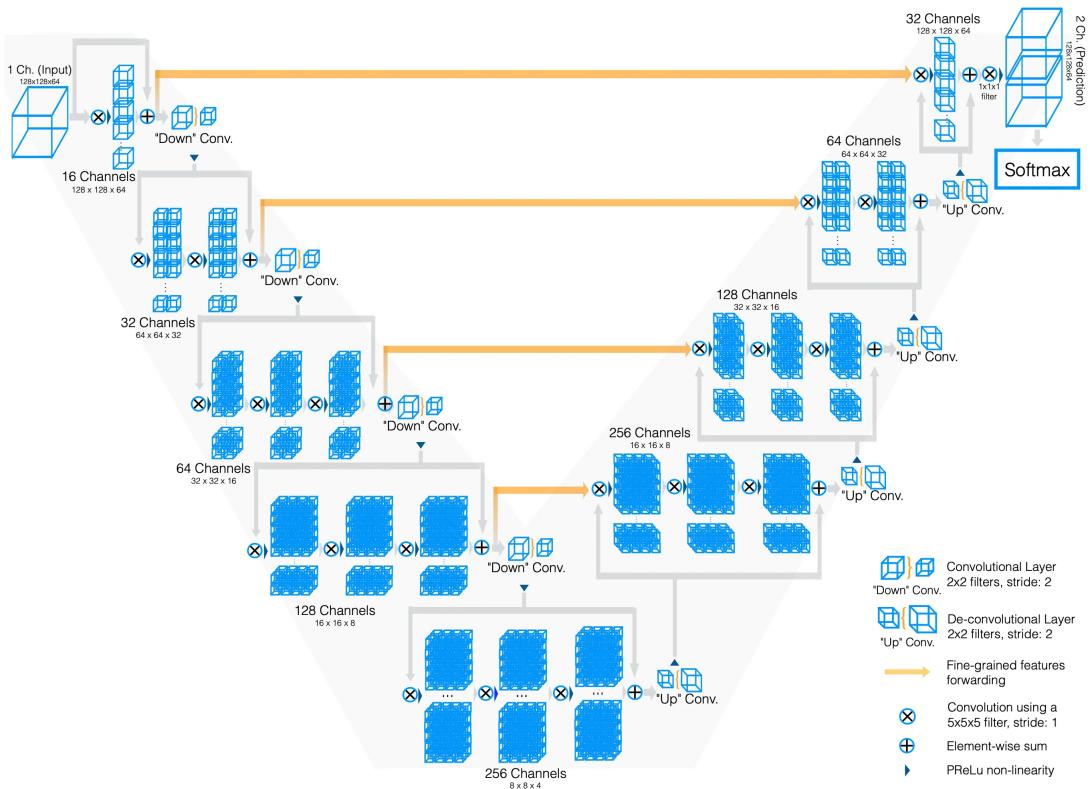
또한, 다른 연구들은 뇌 종양 분할을 위해 혁신적인 분할 아키텍처를 소개했습니다.

예를 들어, Cahall 등(2021)의 DIU-Net이나 Yang 등(2020)의 DCU-Net은 확장된 합성곱과 인셉션 모듈을 활용하여 지역적 구조적 정보와 전역적 맥락 정보를 추출하여 정확한 분할 결과를 얻습니다. 이러한 아키텍처들은 다양한 기술을 결합하여 분할 성능을 향상시키는 발전을 보여줍니다.

요약하면, 분할 아키텍처의 상향식/하향식 접근 방식은 정확한 분할을 위해 특징을 추출하고 차원을 줄이며 해상도를 향상시키는 데 중요한 역할을 합니다. 특히 정확한 지역화와 분류가 진단 및 치료 계획에 중요한 뇌 종양 분할 분야에서 이러한 방법론은 중요한 역할을 합니다.

## ! 인코더 디코더 기반 모델의 keyword 정리

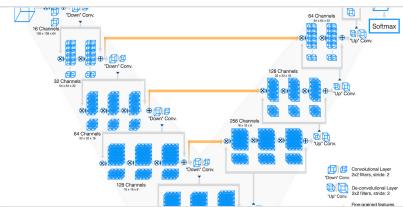
▼ V- net



### V-Net

이 글은 Review: V-Net—Volumetric Convolution (Biomedical Image Segmentation)을 번역한 것입니다.

<https://medium.com/@codecompose/v-net-e90af824c1f3>



- 이를 알기 위해선 3D 컨볼루션의 개념에 대해 이해 해야한다

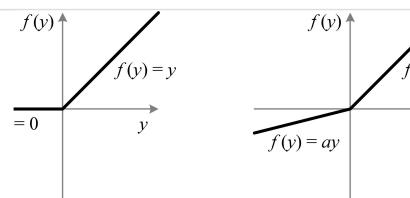
<https://jay.tech.blog/2017/02/02/3d-convolutional-networks/>

### ▼ PReLU

#### Papers with Code - PReLU Explained

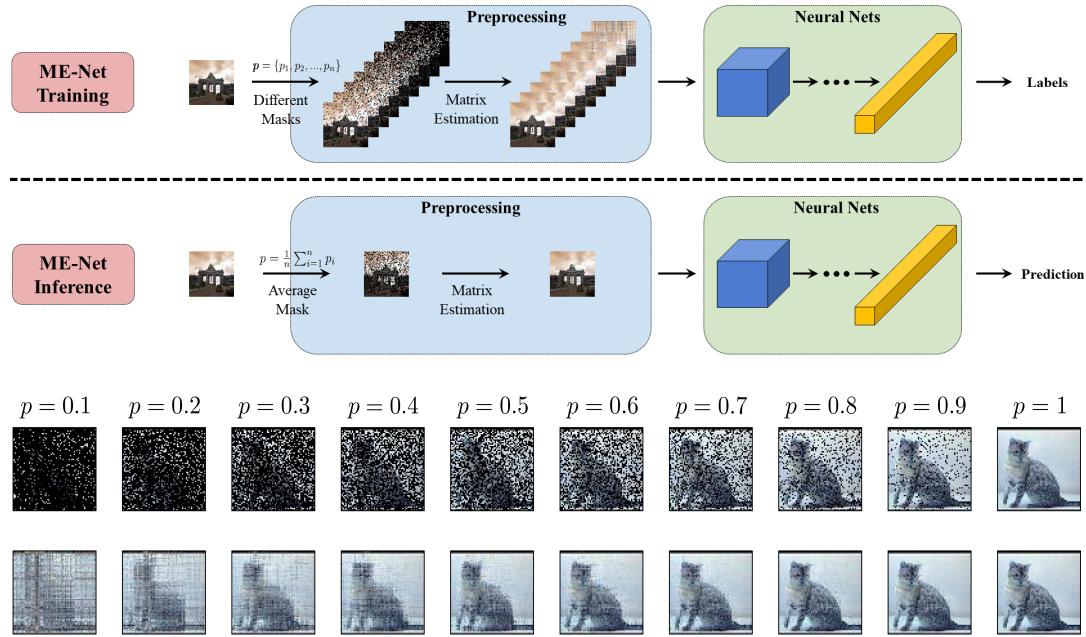
A Parametric Rectified Linear Unit, or PReLU, is an activation function that generalizes the traditional rectified unit with a slope for negative values. Formally:  $f(y_i) = y_i \text{ if } y_i \geq 0; f(y_i) = ay_i \text{ if } y_i < 0$

<https://paperswithcode.com/method/prelu>



### ▼ ME-net

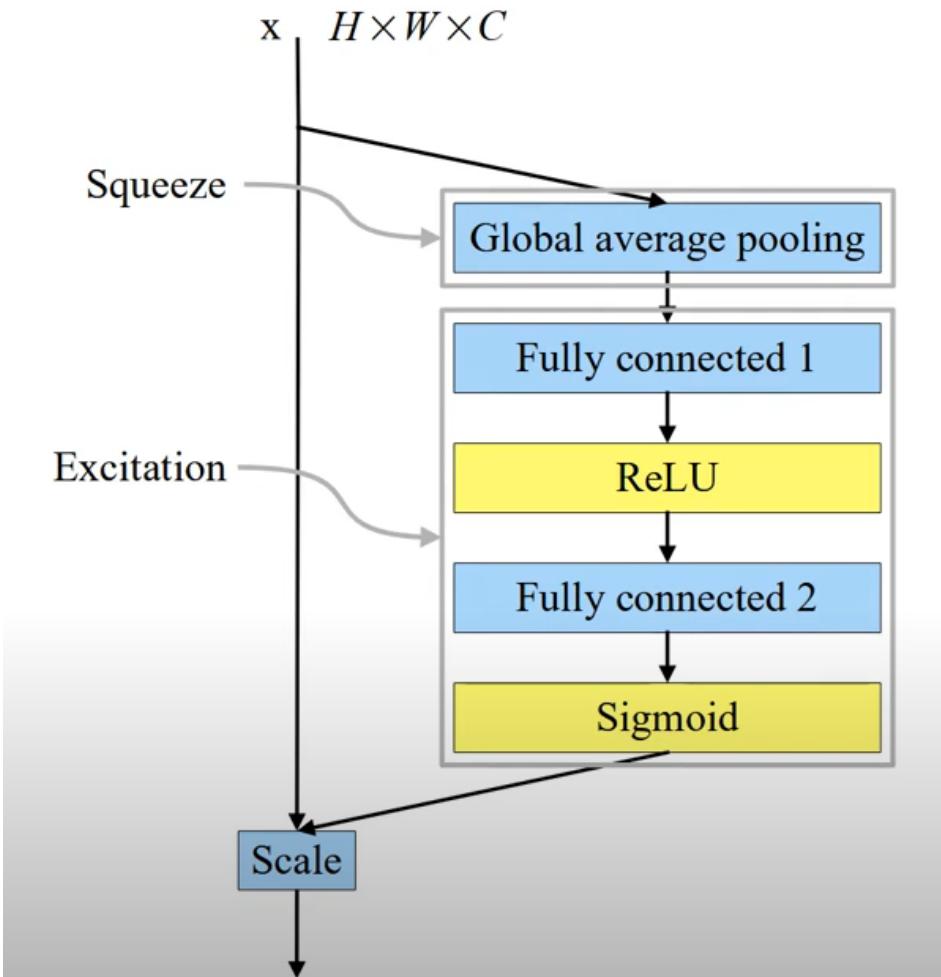
<http://me-net.csail.mit.edu/>



첫 번째 픽셀은 이미지에서 무작위로 삭제됩니다. 그런 다음 ME를 사용하여 이미지가 재구성됩니다. 우리는 이 과정이 잡음의 적대적 구조를 파괴하는 동시에 원본 이미지의 전체 구조를 강화한다는 것을 보여줍니다

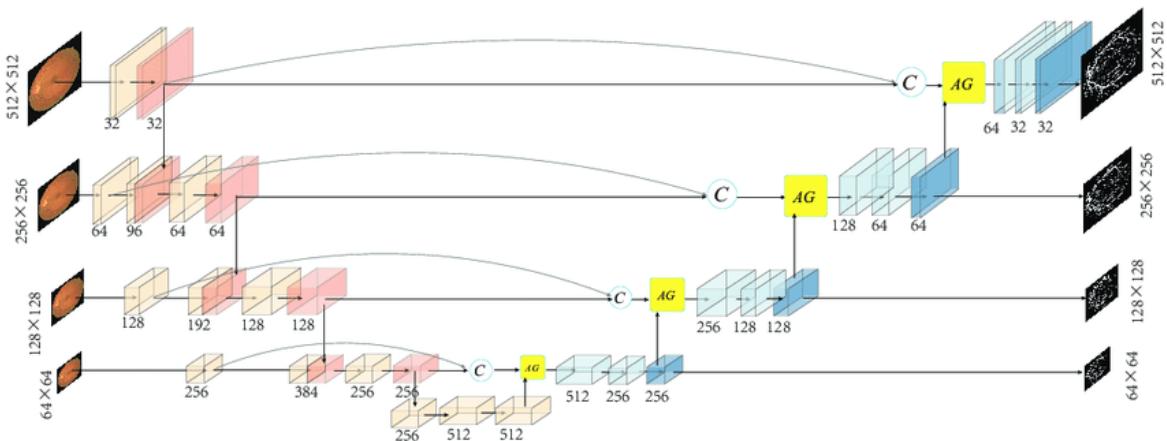
▼ 스퀴즈 앤 익스텐션 블록

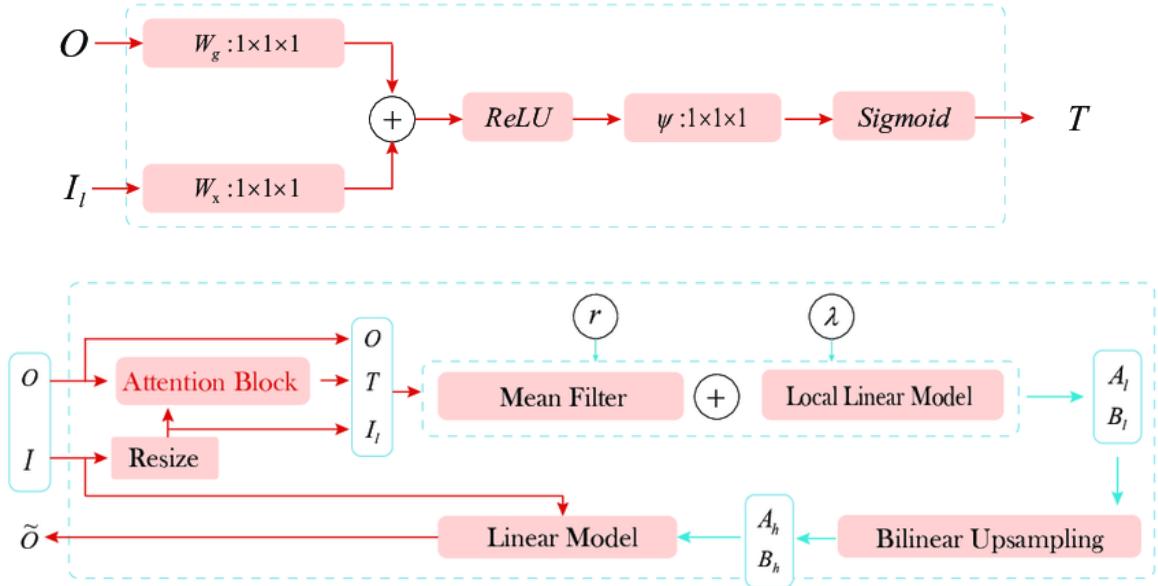
<https://www.youtube.com/watch?v=2d54F5Xw-Wk>



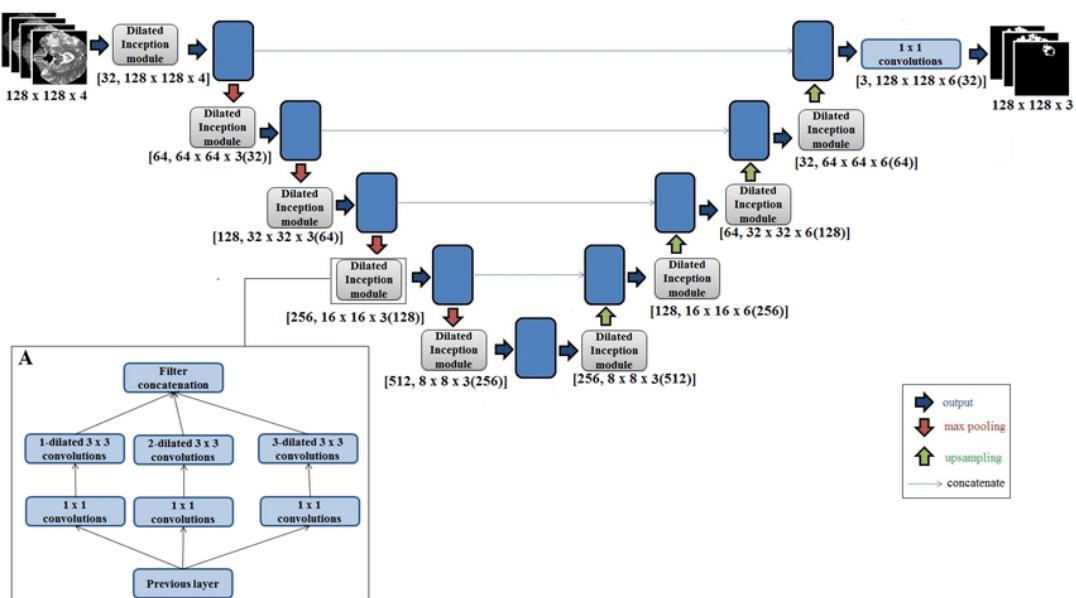
#### ▼ 어텐션 가이드 필터

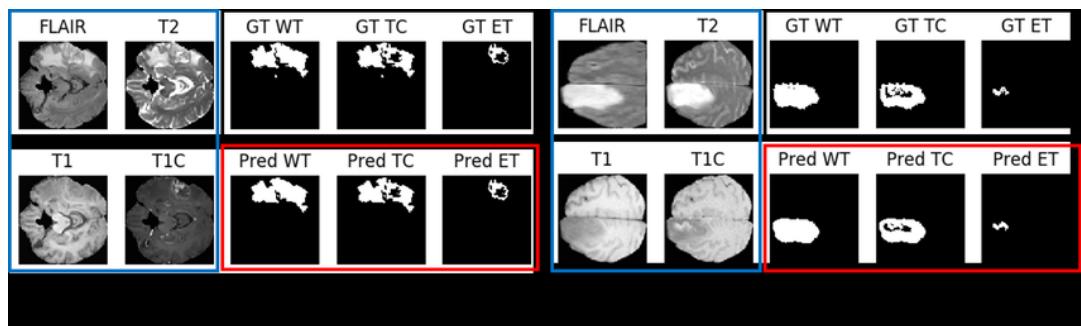
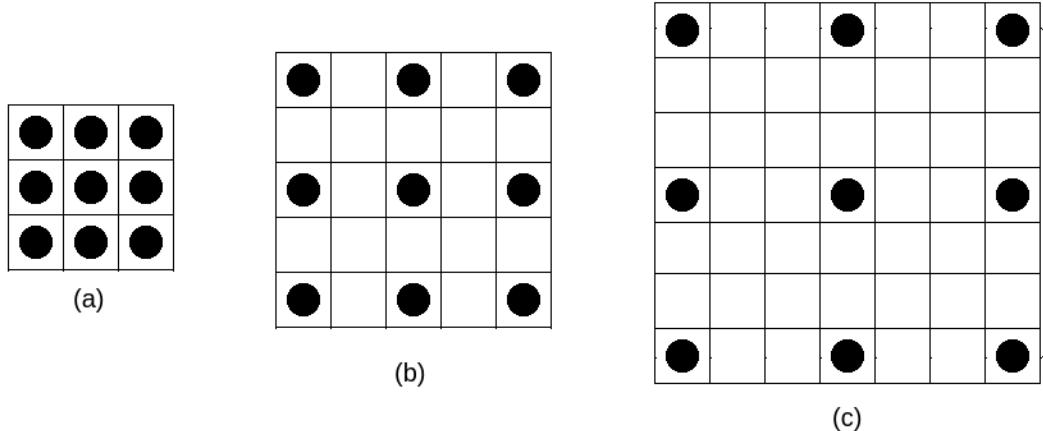
[chrome-extension://efaidnbmnnibpcajpcgjclefindmkaj/https://arxiv.org/pdf/1907.12930](https://arxiv.org/pdf/1907.12930)





### ▼ DIU-net





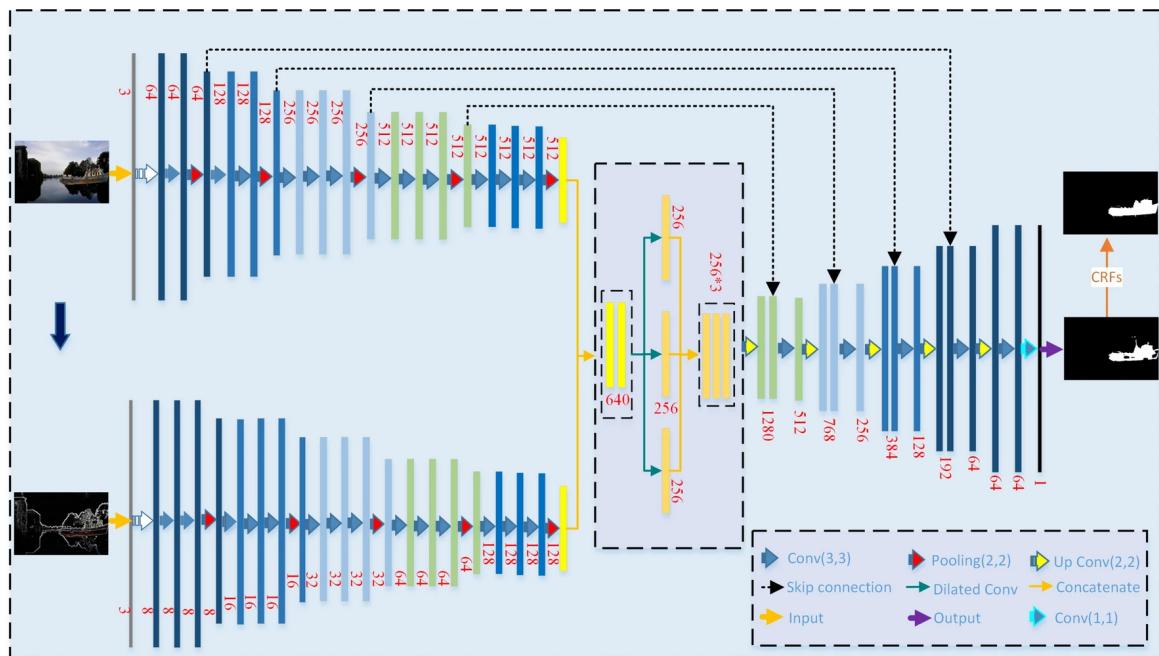
### Dilated Inception U-Net (DIU-Net) for Brain Tumor Segmentation

Magnetic resonance imaging (MRI) is routinely used for brain tumor diagnosis, treatment planning, and post-treatment surveillance. Recently, various models based on deep neural networks have been...

<https://arxiv.org/abs/2108.06772>



### ▼ DCU-net



### DCU-Net: a dual-channel U-shaped network for image splicing forgery detection

Neural Computing and Applications - The detection and location of image splicing forgery are a challenging task in the field of image forensics. It is to study whether an image contains a...

 <https://link.springer.com/article/10.1007/s00521-021-06329-4>

